Uvod u programski jezik Python

Programski jezik Python

- autor: Guido van Rossum, 1991.
- Monty Python's Flying Circus
- Python 2.5.2, veljača 2008.

Literatura i Internet resursi

- *Python homepage* (http://www.python.org/)
- *službeni tutorial* (Guido van Rossum) (http://docs.python.org/tut/tut.html)
- Mark Pilgrim, *Dive Into Python* (on-line book http://diveintopython.org/)
- Mark Lutz, *Learning Python*, 3rd Edition, O'Reilly, 2007
- Mark Lutz, *Programming Python*, 3rd Edition, O'Reilly, 2006

Izvođenje Python programa

- instalacija Python interpretera
  - `cygwin`
  - `Linux` distribucije
  - `Windows`
  - `IDLE` – razvojna okolina (IDE)
  - `python.org`
- izvođenje naredbi/programa
  - interaktivno
  - kao *modul*
  - skripta iz komandne linije

Interaktivno izvođenje naredbi

- pokrenemo python interpreter i ukucavamo naredbu po naredbu
- rezultat s odmah ispisuje

```
$ python
>>> print 'Hello world'!
Hello world!
>>> print 2 ** 8
256
```

- napuštanje interpretera
  `ctrl-D` (ili `ctrl-Z`)
- vrlo prikladno za eksperimentiranje s konstruktima jezika
- testiranje modula od kojih se grade složeniji programi

Programske datoteke

- programe želimo zapamtiti – pohraniti u (tekst) datoteke
  → *moduli*
- primjer: program `prvi.py`

```
print 2 ** 8 # 2^8
tekst = 'the bright side '
print tekst + 'of life' # + je ulancavanje
```

- pokretanje

```
$ python prvi.py
256
the bright side of life
```

- ekstenzija imena (`.py`) nije nužna za "prvu razinu" programa
- ako modul namjeravamo "uvoziti" (*import*), nastavak imena je potreban

Izvršive skripte

- ništa novo :-)
- primjer `drugi`

```
#!/usr/bin/python
print 'leteci cirkus'
```

```
$ chmod +x drugi
$ ./drugi
leteci cirkus
```

- primjena naredbe `env` za postizanje neovisnosti o smještaju Python interpretera

```
#!/usr/bin/env python
```

Učitavanje modula

- svaka datoteka s Python naredbama, čije ime sadrži nastavak `.py` je *modul*
- program može učitati (*import*) neki modul, čime dobiva pristup njegovom sadržaju
- sadržaj modula se stavlja na raspolaganje okolini preko svojih *atributa*
- osnovna ideja programske arhitekture u Pythonu
  - veći programi se obično grade kao skup modula, koji učitavaju alate definirane u drugim modulima

Učitavanje modula (2)

- operacija učitavanja modula, između ostaloga, pokreće izvršavanje naredbi tog modula
  → jedan od načina pokretanja programa

```
$ python
>>> import prvi
the bright side of life
```

- izvođenje naredbi modula obavlja se *samo pri prvom učitavanju* !
  - naknadno učitavanje neće učiniti ništa, čak i ako se kôd modula u međuvremenu promijenio !

```
>>> import prvi
>>> import prvi
```

- učitavanje modula je “skupa” operacija
  - pronaći datoteku
  - prevesti u *byte-code* – (`.pyc`)
  - izvršti naredbe

Ponovno učitavanje modula

- ako (doista) želimo ponovno učitati i izvršiti (eventualno izmijenjeni) modul, možemo to učiniti ugrađenom funkcijom `reload`

```
>>> reload(prvi)
promijenili smo tekst :-)
<module 'prvi' from 'prvi.py'>
```

- `reload` je funkcija, dok je `import` naredba
- samo se uspješno učitani modul može ponovo-učitati

Moduli i atributi

- namjena modula je organizacija biblioteka i alata
- općenito – modul predstavlja prostor imena (*namespace*)
  - imena unutar modula nazivaju se *atributi*
  - tipično – program koji učitava modul dobiva pristup svim imenima pridijeljenima u najvišoj razini modula
  - ta imena su najčešće pridijeljena *uslugama* koje modul nudi (*eksportira*): funkcije, klase, varijable, namijenjene korištenju iz drugih programa
  - pristup tim imenima postiže se naredbama `import` i `from`, te pozivom funkcije `reload`

Moduli i atributi (2)

- primjer: modul `myfile.py`

```
title = "The Meaning of Life"
```

- dva načina pristupa atributima modula
- učitavanje cijelog modula, ime se *kvalificira* imenom modula

```
$ python
>>> import myfile
>>> print myfile.title # kvalificiranje
The Meaning of Life
```

- sintaksa `objekt.atribut` omogućuje pristup atributima bilo kojeg *objekta* i uobičajena je u Pythonu

Moduli i atributi (3)

- drugi način pristupa imenima u modulu (u ovom slučaju radi se o kopiranju!) – korištenjem naredbe `from`

```
$ python
>>> from myfile import title # ime se kopira
>>> print title # ne treba kvalifikacija
The Meaning of Life
```

- `from` kopira atribute iz modula, tako da oni postaju varijable programa koji ih je učitao
- uočiti: imena modula se navode bez nastavka `.py` (Python automatski dodaje nastavak i traži datoteku)
- pri učitavanju izvršavaju se naredbe modula, a komponenta koja je modul učitala dobiva pristup imenima najviše razine modula (objekti poput funkcija i klasa)
  → ponovo iskoristive programske komponente

Moduli i atributi (4)

- obično modul definira više imena, raspoloživih za učitavanje u druge komponente – npr. `tri.py`

```
a = 'dead' # definira 3 atributa
b = 'parrot' # eksportiraju se
c = 'sketch'
print a, b, c # koriste se i u samom modulu
```

```
$ python tri.py
dead parrot sketch
```

- učitavanje modula

```
$ python
>>> import tri # cijeli modul
dead parrot sketch
>>>
>>> tri.b, tri.c # tuple
('parrot', 'sketch')
```

Moduli i atributi (5)

- učitavanje modula naredbom `from`

```
>>>
>>> from tri import a, b, c # kopira
>>> b, c
('parrot', 'sketch')
```

- ugrađena funkcija `dir` omogućuje dobivanje liste svih imena raspoloživih unutar modula

```
>>>
>>> dir(tri)
['__builtins__', '__doc__', '__file__',
['__name__', 'a', 'b', 'c']
```

- kada se `dir` pozove s imenom učitanog modula, vraća listu svih atributa unutar tog modula
- neka od imena su ugrađena (počinju i završavaju dvostrukom podvlakom) – Python ih unaprijed definira i imaju posebna značenja za interpreter

Struktura Python programa

- Python programi mogu se razložiti na module, izraze i objekte
  - programi se grade od modula
  - moduli sadrže naredbe
  - naredbe sadrže izraze
  - izrazi stvaraju i obrađuju objekte

Ugrađeni tipovi podataka

- Python nudi moćne tipove objekata kao sastavni dio jezika
  - ugrađeni tipovi omogućavaju lako pisanje jednostavnih programa
  - liste
  - rječnici
- obično su ugrađeni tipovi učinkovitiji od nadograđenih struktura podataka
  - koriste se optimirani algoritmi za baratanje strukturama podataka, koji su zbog brzine pisani u C-u

Ugrađeni tipovi podataka (2)

- tipovi podataka u Pythonu

Tip objekta	Primjer literala/stvaranja
Broj	`3.1415, 1234, 999L, 3+4j`
Znakovni niz	`'spam', "guido's"`
Lista	`[1, [2, 'three'], 4]`
Rječnik	`{'food': 'spam', 'taste': 'yum'}`
n-torka	`(1,'spam', 4, 'U')`
datoteka	`text = open('eggs', 'r').read( )`

Brojevi

- primjeri literala

Literal	Interpretacija
`1234, -24, 0`	Normal integers (C longs)
`99999999999999999L`	Long integers (unlimited size)
`1.23, 3.14e-10, 4E210`	Floating-point (C doubles)
`0177, 0x9ff, 0XFF`	Octal and hex literals
`3+4j, 3.0+4.0j, 3J`	Complex number literals

- cjelobrojni literal koji završava s `L` ili `l` je Python `long integer` – proizvoljne veličine
- od verzije 2.2 cijeli brojevi koji prekorače opseg automatski postaju *dugi* – oznaka `L` nije neophodna
- kompleksni brojevi – imaginarni dio završava s `J` ili `j`
- interno su to parovi `floating point` brojeva

Operatori

- tablica (prednost raste prema dnu tablice)

Operatori	Opis
`lambda args: expression`	neimenovana funkcija
`x or y`	y se evaluira ako je x false
`x and y`	y se evaluira ako je x true
`not x`	logička negacija

`x < y, x <= y, x > y, x >= y,`
`x == y, x <> y, x != y,`
`x is y, x is not y,`
`x in y, x not in y`
	usporedbe
	
	provjera identiteta
	pripadnost sekvenci

Operatori (2)

- tablica (nastavak)

Operatori	Opis
`x | y`	Bitwise or
`x ^ y`	Bitwise exclusive or
`x & y`	Bitwise and
`x << y, x >> y`	Shift x left or right by y bits
`-x + y, x - y`	Addition/concatenation, subtraction
`x * y, x % y, x / y, x // y`	Multiplication/repetition, remainder/format, division
`-x, +x, ~x, x ** y`	..., bitwise complement; potencija
`x[i], x[i:j], x.attr, x(...)`	Indexing, slicing, qualification, function calls
`(...), [...], {...}, '...'`	Tuple, list, dictionary, conversion to string

- redoslijed primjene operatora
- grupiranje izraza zagradama

Miješanje tipova

- u izrazima u kojima se pojavljuju različiti tipovi podataka, Python se ponaša kao i drugi programski jezici – operandi se pretvaraju u najsloženiji tip

```
40 + 3.14
```

- složenost tipova u Pythonu
  - integer
  - long integer
  - floating-point
  - complex number
- od verzije 2.2 `integer` se pretvara u `long integer` ako vrijednost postane prevelika
- pretvaranja se obavljaju između *numeričkih* tipova
  - općenito, Python ne obavlja pretvorbe između ostalih tipova
  - npr. pribrajanje znakovnog niza cijelom broju generira pogrešku, osim ako "ručno" obavimo pretvorbu

Varijable

- varijable se stvaraju kada im se prvi puta dodjeljuje vrijednost

```
$ python
>>> a = 3        # Name created
>>> b = 4
```

- u izrazima se varijable zamjenjuju njihovim vrijednostima
- da bismo varijablu mogli koristiti u izrazu, mora joj biti dodijeljena vrijednost
- varijable se odnose na konkretne objekte i nikada se ne deklariraju unaprijed

Numerički izrazi

- primjeri

```
>>> a = 3
>>> b = 4
>>> b * 3, b / 2 # (4*3), (4/2)
(12, 2)

>>> a % 2, b ** 2 # modulo, potencija
(1, 16)

>>> 2 + 4.0, 2.0 ** b # pretvorba tipova
(6.0, 16.0)
```

- u interaktivnom načinu rada rezultat izraza se automatski ispisuje
- dva izraza odvojena zarezom -> rezultat je n-torka

Numerički izrazi (2)

- ako se u izrazu koristi varijabla kojoj nije dodijeljena vrijednost, Python prijavljuje grešku, a ne koristi neku pretpostavljenu vrijednost

```
>>> c * 2
Traceback (most recent call last):
  File "<stdin>", line 1, in ?
NameError: name 'c' is not defined
```

- redoslijed primjene operatora i grupiranje zagradama

```
>>> b / 2 + a        # kao ((4 / 2) + 3)
5
>>> print b / (2.0 + a) # kao (4 / (2.0 + 3))
0.8
```

Prikaz brojeva

- upotreba naredbe `print` i automatski ispis

```
>>> b / (2.0 + a)      # Auto echo output: more digits
0.80000000000000004
>>> print b / (2.0 + a) # print rounds off digits
0.8
```

- automatski ispis prikazuje *sve* znamenke rezultata, u konkretnom primjeru razlog je pogreška u FP prikazu/aritmetici

```
>>> 1 / 2.0 # laki brojevi :-)
0.5
```

- naredba `print` zaokružuje brojeve koje ispisuje

Prikaz brojeva (2)

- upravljanje prikazom – upravljanje formatom znakovnih nizova

```
>>> num = 1 / 3.0
>>> num                  # Echoes
0.33333333333333331
>>> print num            # Print rounds
0.333333333333

>>> "%e" % num           # String formatting
'3.333333e-001'
>>> "%2.2f" % num        # String formatting
'0.33'
```

Dijeljenje

- klasično dijeljenje – kad se dijele cijeli brojevi, necijeli dio rezultata se odbacuje; pri dijeljenju brojeva s pomičnim zarezom, nema odbacivanja necijelog dijela

```
X / Y
```

```
>>> (5 / 2), (5 / 2.0), (5 / -2.0), (5 / -2)
(2, 2.5, -2.5, -3)
```

- dijeljenje s “odsijecanjem” – necijeli dio rezultata se odbacuje, neovisno o tipu operanada

```
X // Y
```

```
>>> (5 // 2), (5 // 2.0), (5 // -2.0), (5 // -2)
(2, 2.0, -3.0, -3)
```

- razlog dodavanja – ovisnost rezultata o tipu operanada je nezgodan kod jezika s dinamičkim tipovima podataka !

Operacije nad bitovima

- *bitwise* operacije – posmak, I, ILI

```
>>> x = 1 # 0001
>>> x << 2 # Shift left 2 bits: 0100
4
>>> x | 2 # bitwise OR: 0011
3 >>> x & 1 # bitwise AND: 0001
1
```

- operacije nad bitovima nisu baš uobičajene kao u jezicima niže razine poput C-a
  - "... if you find yourself wanting to flip bits in Python, you should think about which language you're really coding"

Dugi zapis cijelih brojeva

- u Python-u cijeli brojevi u dugom zapisu (oznaka `L`) mogu biti *proizvoljne* duljine – ograničenje je jedino količina memorije

```
>>> 99999999999999999999999999999999999999L + 1
100000000000000000000000000000000000000L
```

  - od verzije 2.2 oznaka `L` nije nužna – automatska pretvorba
  - ranije verzije – preljev

- mogućnost računanja s vrlo velikim brojevima, naravno aritmetika s dugim brojevima je puno sporija od obične

```
>>> 2 ** 200
1606938044258990275541962092341162602522202993782792835301376L
```

Kompleksni brojevi

- kompleksni brojevi su ugrađeni tip podataka u Pythonu
  - izvedeni kao parovi brojeva s pomičnim zarezom, pri čemu se imaginarni dio označava dodavanjem oznake `J` ili `j`, realni i imaginarni dio povezani su oznakom `+`
  - npr. kompleksni broj čiji je realni dio `2` i imaginarni dio `-3` zapisuje se `2 + -3j`
- primjeri

```
>>> 1j * 1J
(-1+0j)
>>> 2 + 1j * 3
(2+3j)
>>> (2+1j)*3
(6+3j)
```

- nad kompleksnim brojevima podržani su uobičajeni matematički izrazi, te dodatni alati sadržani u standardnom modulu `cmath`

Heksadekadska i oktalna notacija

- kao u C-u: oktalni literali započinu s `0`, heksadekadski s `0x` ili `0X`

```
>>> 01, 010, 0x10, 0xFF
(1, 8, 16, 255)
```

- ispis je uobičajeno dekadski, ali postoje ugrađene funkcije za pretvorbu u heksa/oktalne *znakovne nizove*

```
>>> oct(64), hex(64), hex(255)
('0100', '0x40', '0xff')
```

- obrnuta pretvorba – iz znakovnog niza koji sadrži broj u broj – ugrađena funkcija `int`, drugi argument određuje brojevnu bazu

```
>>> int('0100'), int('0100', 8), int('0x40', 16)
(100, 64, 64)
```

- izrazi za formatiranje znakovnih nizova

```
>>> "%o %x %X" % (64, 63, 255)
'100 3f FF'
```

Ostali numerički alati

- Python sadrži ugrađene funkcije i ugrađene *module* za matematiku
- par primjera

```
>>> import math
>>> math.pi, math.e
(3.1415926535897931, 2.7182818284590451)

>>> math.sin(2 * math.pi / 180)
0.034899496702500969

>>> abs(-42), 2**4, pow(2, 4) # ugradjene f-je
(42, 16, 16)

>>> int(2.567), round(2.567), round(2.567, 2)
(2, 3.0, 2.5699999999999998)
```

Dinamičko upravljanje tipovima

- upoznali smo Perl i ljusku, pa nam to više nije novo :-)
- tipovi podataka određuju se automatski tijekom izvođenja programa, a ne na temelju deklaracija u programskom kodu
  - varijabla se stvara kada joj se u programu prvi put dodijeli vrijednost
  - kasnije dodjele vrijednosti mijenjaju vrijednost pridruženu varijabli
  - varijable (*imena*) ne sadrže informaciju o tipu podatka – tip je pridružen *objektu* a ne imenu
    $\rightarrow$ varijabla naprosto pokazuje na neki objekt
  - kada se varijabla pojavljuje u izrazu, zamjenjuje se objektom na koji pokazuje
  - da bi mogla biti upotrijebljena u izrazu, varijabli *mora biti dodijeljena vrijednost* – inače greška

Varijable

- varijable su *reference* na objekte

```
>>> a = 3
```

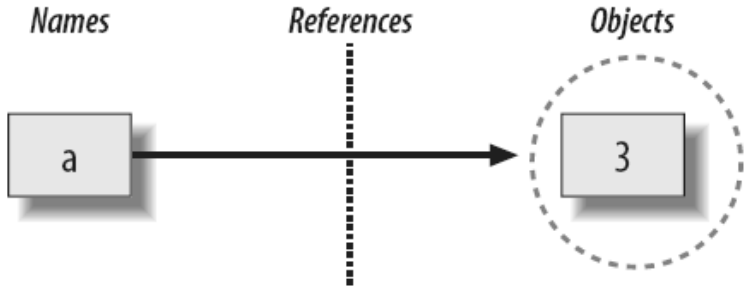

- što ako varijabli pridružimo vrijednost druge varijable ?
  → *dijeljene reference*

```
>>> a = 3
>>> b = a
```

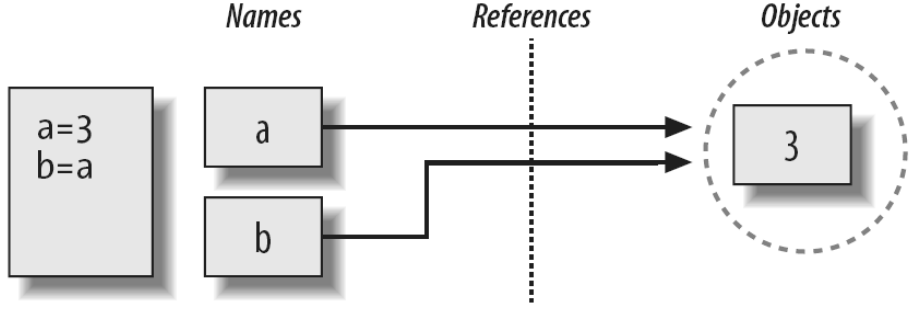

Varijable (2)

- što ako nakon toga varijabli `a` dodijelimo novu vrijednost ?

```
>>> a = 3
>>> b = a
>>> a = 'spam'
```

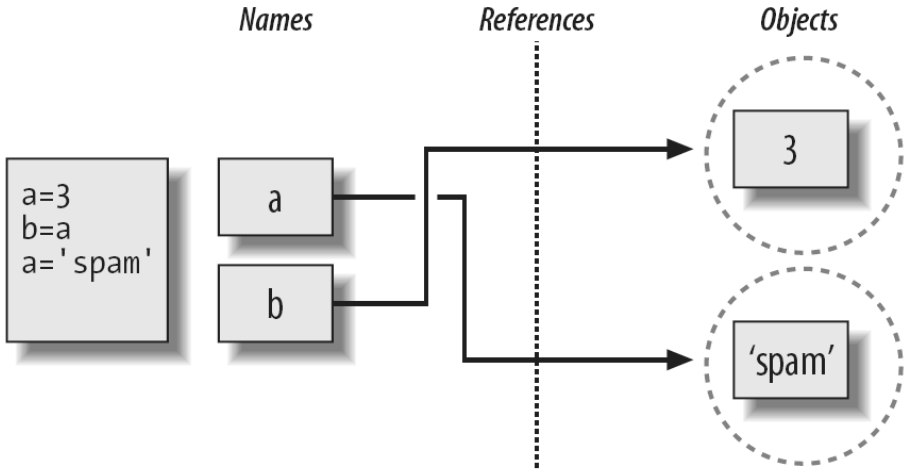

- stvoren je novi objekt (znakovni niz), s kojim se povezuje varijabla `a`
- ne utječe se na varijablu `b` – ona i dalje pokazuje na isti objekt
- varijabla `a` pokazuje na objekt drugačijeg tipa
  → tip je svojstvo objekta, a ne imena (varijable)

Reference i izmjenjivi objekti

- slično kao u gornjem primjeru (samo bez različitog tipa objekta):

```
>>> a = 3
>>> b = a
>>> a = 5
```

  - drugo dodjeljivanje vrijednosti varijabli `a` ne utječe na objekt na koji ona pokazuje, a time ni na vrijednost varijable `b`
  - cijeli brojevi (kao ni znakovni nizovi) su objekti koji se ne mogu izmijeniti – *nepromjenljivost* (*immutability*)
- postoje vrste objekata i operacije nad njima koje uzrokuju izmjenu objekata "na licu mjesta"
  - npr. operacije nad listama uzrokuju promjene elemenata, a ne stvaranje nove liste
  - kod takvih objekata treba paziti na dijeljene reference, jer promjena korištenjem jednog imena utječe i na vrijednost na koju pokazuje drugo ime !

Reference i izmjenjivi objekti (2)

- primjer

```
>>> L1 = [2,3,4]
>>> L2 = L1
```

  - varijable `L1` i `L2` pokazuju na istu listu
  - ako varijabli `L1` dodijelimo kao novu vrijednost cijeli broj, reference se razdvajaju, a lista ostaje netaknuta

```
>>> L1 = 24
```

  - no, ako preko `L1` dodijelimo novu vrijednost jednom elementu liste, lista se mijenja (i za `L2`)

```
>>> L1[0] = 24
>>> L2
[24, 3, 4]
```

Reference i prikupljanje otpada

- kada se varijabla poveže se novim objektom, Python provjerava referencira li “napušteni” objekt neka druga varijabla (ili neki drugi objekt) i preuzima objekte bez reference
  → *garbage collection*
- primjer

```
>>> x = 42
>>> x = 'shrubbery' # Reclaim 42 now (?)
>>> x = 3.1415     # Reclaim 'shrubbery' now (?)
>>> x = [1,2,3]    # Reclaim 3.1415 now (?)
```

Znakovni nizovi

- *string* – uređena kolekcija znakova
- Python ima moćan skup alata za obradu znakovnih nizova
- Python nema posebnog tipa za pojedinačni znak
- znakovni nizovi svrstavaju se u nepromjenjive sekvence (*immutable sequences*)
  - znakovni niz ne može se mijenjati – možemo jedino stvoriti novi s promijenjenim sadržajem
  - sekvence su posebna kategorija podatkovnih tipova, operacije nad svim tipovime te kategorije su slične
- regularni izrazi (standardni modul)

Operacije nad znakovnim nizovima

Operacija	Opis
`s1 = ''`	prazni niz
`s2 = "spam's"`	dvostruki navodnici
`block = """..."""`	*blok* – može se protezati kroz više redaka
`s3 = r'\temp\spam'`	"sirovi" znakovni niz
`s4 = u'spam'`	Unicode Strings
`s1 + s2 ; s2 * 3`	ulančavanje, ponavljanje
`s2[i] ; s2[i:j] ; len(s2)`	indeksiranje, izrezivanje, duljina
`"a %s parrot" % 'dead'`	formatiranje

`s2.find('pa')`
`s2.replace('pa', 'xx')`
`s1.split( )`
	pozivanje metoda

`for x in s2`	iteriranje
`'m' in s2`	pripadnost

Znakovni nizovi – literali

- razni načini zapisivanja
  - jednostruki navodnici: `'spa"m'`
  - dvostruki navodnici: `"spa'm"`
  - trostruki navodnici:
    `'''... spam ...''', """... spam ..."""`
  - *escape* sekvence: `"s\tp\na\0m"`
  - sirovi string: `r"C:\new\test.spm"`
  - Unicode string: `u'eggs\u0020spam'`
- jednostruki i dvostruki navodnici – ekvivalentni
  → oba oblika djeluju jednako i vraćaju isti tip objekta

```
>>> 'student',"student"
('student', 'student')
```

Navodnici

- primjena različitih navodnika omogućuje gniježdenje navodnika (druge vrste) unutar znakovnog niza:

```
>>> 'knight"s', "knight's"
('knight"s', "knight's")
```

- Python automatski nadovezuje susjedne znakovne nizove literale i bez eksplicitnog korištenja operatora nadovezivanja (+)

```
>>> title = "Meaning " 'of' " Life"
>>> title
'Meaning of Life'
```

- uključivanje navodnika u znakovni niz moguće je i predznačivanjem s \

```
>>> 'knight\'s', "knight\"s"
("knight's", 'knight"s')
```

Escape sekvence

- predznačavanje s `\` omogućuje umetanje specijalnih znakova u nizove (*escape sekvence*)

```
>>> s = 'a\nb\tc'
```

- interaktivni automatski ispis prikazuje specijalne znakove kao escape sekvence

```
>>> s
'a\nb\tc'
```

- ispis naredbom `print` interpretira specijalne znakove

```
>>> print s
a
b       c
```

- duljninu znakovnog niza možemo dozneti primjenom funkcije `len`

```
>>> len(s)
5
```

Escape sekvence (2)

- tablica escape sekvenci

Escape	Značenje
`\<novi_red>`	ignorira se – nastavljanje retka
`\\`	Backslash
`\'`	jednostruki navodnik
`\"`	dvostruki navodnik
`\a`	Bell
`\b`	Backspace
`\f`	Formfeed
`\n`	Newline (linefeed)
`\r`	Carriage return
`\t`	Horizontal tab
`\v`	Vertical tab

Escape sekvence (3)

- tablica escape sekvenci (nastavak)

Escape	Značenje
`\N{id}`	Unicode dbase id
`\uhhhh`	Unicode 16-bit hex
`\Uhhhh...`	Unicode 32-bit hex
`\xhh`	Hex digits value hh
`\ooo`	Octal digits value
`\0`	Null (doesn't end string)
`\other`	Not an escape (kept)

Binarni znakovi u nizovima

- u Pythonu *null-znak* ne predstavlja kraj niza (kao ni u Perlu) – Python vdi računa o duljini stringa
- znakovni nizovi mogu sadržavati proizvoljne binarne znakove

```
>>> s = '\001\002\x03'
>>> s
'\x01\x02\x03'
>>> len(s)
3
```

- mogućnost učitavanja i obrade binarnih podataka u znakovnim nizovima

Sirovi znakovni nizovi

- u “sirovim” znakovnim nizovima ne interpretiraju se escape sekvence

```
ne_valja = open('C:\new\text.dat', 'w')
```

- sirovi niz označava se slovom `r` ili `R`

```
bolje = open(r'C:\new\text.dat', 'w')
```

- naravno, može i običnim stringom

```
moze = open('C:\\new\\text.dat', 'w')
```

- Python koristi ovakav način ispisa `"\"` unutar stringova

```
>>> path = r'C:\new\text.dat'
>>> path # Show as Python code.
'C:\\new\\text.dat'
>>> print path # "User-friendly" format
C:\new\text.dat
>>> len(path)
15
```

Trostruki navodnici

- Python podržava zapisivanje znakovnih nizova koji se protežu kroz više redaka – navode se unutar trostrukih navodnika
- sintaksno – blok započinje s tri navodnika (jednostruka ili dvostruka), slijedi proizvoljan broj redaka teksta, a završetak bloka označava pojava tri navodnika (jednaka početnim)
- unutar bloka mogu se pojaviti i navodnici i ne moraju biti predznačeni s `"\"`

```
>>> mantra = """Always look
... on the bright
... side of life."""
>>>
>>> mantra
'Always look\n on the bright\nside of life.'
```

- Python prikuplja sve retke ovako definiranog bloka teksta i pakira ga u jedan niz, pri čemu se prelasci u novi red kodiraju kao `"\n"`

Operacije sa znakovnim nizovima

- duljina niza

```
$ python
>>> len('abc')
3
```

- ulančavanje

```
>>> 'abc' + 'def'
'abcdef'
```

- ponavljanje

```
>>> 'bla ' * 4
'bla bla bla bla '
>>> print '-'*80 # primjer korisne uporabe :-)
```

- ulančavanjem dva znakovna niza *stvara se novi* niz
- za razliku od C-a, nije potrebno alocirati memoriju i voditi računa o veličini polje u koje se niz pohranjuje

Operacije sa znakovnim nizovima (2)

- primjena `"+"` i `"*"` na znakovnim nizovima primjer je *preopterećenja operatora*
- paziti na miješanje tipova !

  `'abc'+9`
  izaziva pogrešku – broj se ne pretvara automatski u niz
- kroz nizove se može prolaziti (*iterirati*) u petlji, uz provjeru pripadnosti operatorom `in`

```
>>> myjob = "hacker"
>>> for c in myjob: print c, # Step through items
...
h a c k e r
>>> "k" in myjob
True
>>> "ack" in myjob # moze i podniz
True
>>> "z" in myjob # False = (nije nadjen)
False
```

Indeksiranje i izrezivanje

- znakovni niz u Pythonu je definiran kao *uređena kolekcije* znakova, svakom se znaku može pristupiti na temelju njegovog indeksa – rezultat operacije je *niz* duljine 1 znak
  - indeksi kreću od `0`
  - negativni indeksi pribrajaju se *duljini niza*, što odgovara brojanju elemenata od kraja niza

```
>>> S = 'spam'
>>> S[0], S[-2] # Indexing from front or end
('s', 'a')
```

- izrezivanje (*slicing*) stvara novi znakovni niz koji sadrži podniz izvornog niza

```
>>> S[1:3], S[1:], S[:-1] # Slicing: extract section
('pa', 'pam', 'spa')
```

```
>>> kopija = S[:] # jednostavan nacin kopiranja
>>> kopija
'spam'
```

Izrezivanje

- ilustracija indeksa pri izrezivanju

[start:end]
Indexes refer to places the knife "cuts."

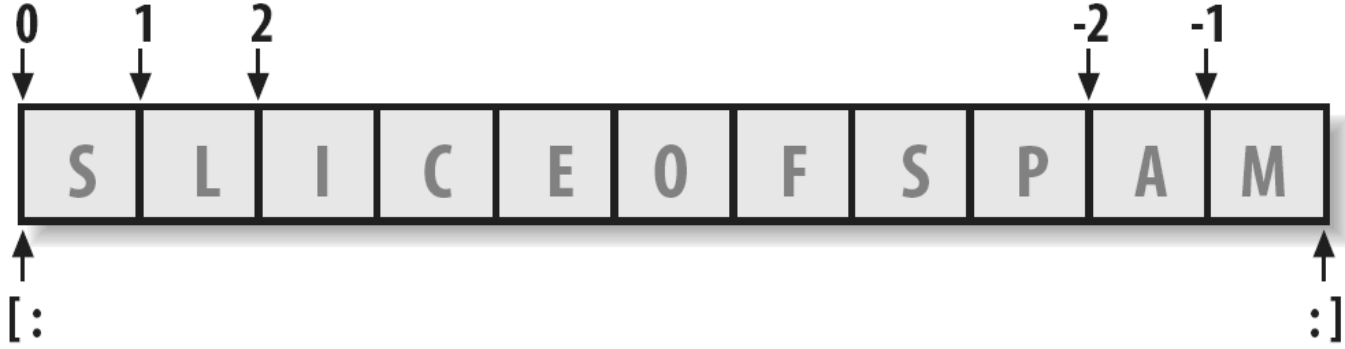

Defaults are beginning of sequence and end of sequence.

- pri operaciji izrezivanja navode se dva indeksa odvojena dvotočkom – prvi indeks označava prvi element koji se izrezuje, a drugi pokazuje *iza* zadnjeg elementa koji se izrezuje
  - ako se izostavi prvi indeks, podrazumijeva se `0`
  - podrazumijevana vrijednost drugog indeksa je duljina niza
  - od verzije 2.3 podržava se i treći "indeks", koji predstavlja *korak izrezivanja*

Pretvorbe znakovnih nizova

- Python ne dozvoljava zbrajanje broja sa znakovnim nizom, čak ni ako niz sliči na broj
  - budući da operator `"+"` može označavati zbrajanje ili ulančavanje, izbor pretvorbe bio bi *dvosmislen*
- Pyton ima alate za pretvorbu znakovnih nizova u cijele brojeve i obrnuto

```
>>> int("42"), str(42) # Convert from/to string
(42, '42')

>>> int("42") + 1  # Force addition
43

>>> "spam" + str(42)  # Force concatenation
'spam42'
```

Pretvorbe znakovnih nizova (2)

- slično – ugrađene funkcije za pretvorbu brojeva s pomičnom točkom

```
>>> str(3.1415), float("1.5")
('3.1415', 1.5)

>>> text = "1.234E-10"
>>> float(text)
1.2340000000000001e-010
```

Izmjena znakovnih nizova

- znakovni nizovi su *nepromjenljive* (*immutable*) sekvence
  → ne mogu se mijenjati (npr. dodjeljivanjem vrijednosti nekom elementu preko indeksa)

```
>>> S = 'spam'
>>> S[0] = "x"
TypeError: object does not support item assignment
```

- kako bismo izmijenili znakovni niz, moramo kreirati novi niz s izmijenjenim sadržajem, uz eventualno pridjeljivanje imenu izvornog stringa

```
>>> S = S + 'SPAM!' # kreira se novi string!
>>> S
'spamSPAM!'

>>> S = S[:4] + 'Burger' + S[-1]
>>> S
'spamBurger!'
```

Formatiranje znakovnih nizova

- Python preopterećuje binarni operator `"%"` – kada se primjeni na znakovne nizove, obavlja ulogu poput funkcije `sprintf` u C-u
  - jednostavno formatiranje vrijednosti u znakovne nizove
  - lijevo od operatora `"%"` navodi se formatni niz u kojem se definiraju pretvorbe podataka
  - na desnoj strani se navodi objekt, ili više objekata u zagradama (*n-torka*), koje želimo umetnuti u konačni znakovni niz
  - tehnički gledano, isti rezultat možemo ostvariti ulančavanjima i pretvorbama, no formatiranje mogućava obavljanje većeg broja koraka u jednu operaciju

```
>>> ime = "Fiona"
>>> "The knight loves %s." % ime

>>> "%d %s %d you" % (1, 'spam', 4)
'1 spam 4 you'
```

Formatiranje znakovnih nizova (2)

- svaki tip objekta može se pretvoriti u string

```
>>> "%s -- %s -- %s" % (42, 3.14159, [1, 2, 3])
'42 -- 3.14159 -- [1, 2, 3]'
```

- za formatiranje raznih tipova podataka na raspolaganju je cijeli niz formatskih kodova – podržani su svi formati koji se koriste u C funkciji `printf`
- tablica formatskih kôdova

Kôd	Opis
`%s`	znakovni niz, ili bilo koji objekt
`%r`	kao `%s`, ali koristi `repr( )`, a ne `str( )`
`%c`	znak
`%d`	dekadski cijeli broj

Formatiranje znakovnih nizova (3)

- tablica formatskih kôdova (nastavak)

Kôd	Opis
`%i`	cijeli broj
`%u`	cijeli broj bez predznaka
`%o`	oktalni cijeli broj
`%x`	heksadekadski cijeli broj
`%X`	heksadekadski cijeli broj, zapis velikim slovima
`%e`	eksponencijalni zapis broja s pomičnom točkom
`%E`	kao `%e` ali veliki E
`%f`	floating-point decimal
`%g`	floating-point `%e` ili `%f`
`%G`	floating-point `%E` ili `%f`
`%%`	doslovno "`%`"

Formatiranje znakovnih nizova (4)

- kodovi za pretvorbu podržavaju detaljnije specificiranje formata
- opća struktura je:

  `%[(name)][flags][width][.precision]code`

- između znaka `%` i koda pretvorbe mogu se navesti: ključ rječnika, lista zastavica (npr. `-` označava lijevo poravnavanje, `+` označava predznak, `0` popunjavanje vodećim nulama), ukupna širina polja, te broj znamenaka iza decimalne točke

```
>>> x = 1234
>>> res = "integers: ...%d...%-6d...%06d" % (x, x, x)
>>> res
'integers: ...1234...1234 ...001234'

>>> x = 1.23456789
>>> x
1.2345678899999999
```

Formatiranje znakovnih nizova (5)

- brojevi s pomičnom točkom mogu se formatirati na različite načine

```
>>> x = 1.23456789
>>> '%e | %f | %g' % (x, x, x)
'1.234568e+000 | 1.234568 | 1.23457'

>>> '%-6.2f | %05.2f | %+06.1f' % (x, x, x)
'1.23 | 01.23 | +001.2'

>>> "%s" % x, str(x)
('1.23456789', '1.23456789')
```

Formatiranje znakovnih nizova (6)

- formatiranje nizova omogućuje i referenciranje elemenata rječnika navedenog na desnoj strani, putem ključa

```
>>> "%(n)d %(x)s" % {"n":1, "x":"spam"}
'1 spam'
```

- ovaj trik se često koristi zajedno s ugrađenom funkcijom `vars`, koja vraća rječnik koji sadrži sve varijable koje *postoje* na mjestu na kojem je funkcija pozvana

```
>>> food = 'spam'
>>> age = 40
>>> vars( )
{'food': 'spam', 'age': 40, ...i ostale... }
```

- ovako se iz formatnog stringa može referencirati varijable imenom (ključ rječnika)

```
>>> "%(age)d %(food)s" % vars( )
'40 spam'
```

Metode znakovnih nizova

- znakovni niz kao objekt ima skup metoda (funkcija koje su atributi objekta), koje implementiraju razne zadatke obrade teksta
  - fukcije su *paketi* kôda, a poziv metode objedinjuje dvije operacije: dohvat atributa i poziv funkcije
  - izraz oblika `objekt.atribut` dohvaća vrijednost atributa u objektu
  - izraz oblika `funkcija(argumenti)` poziva kod funkcije, pri čemu se prosljeđuje nula ili više objekata-argumenata odvojenih zarezima, i vraća se povratna vrijednost funkcije
  - izraz oblika `objekt.funkcija(argumenti)` poziva metodu

Metode znakovnih nizova (2)

- znakovni nizovi su nepromjenljivi – nužno je stvoriti novi string

```
>>> S = 'spammy'
>>> S = S[:3] + 'xx' + S[5:]
>>> S
'spaxxy'
```

- zamjena podniza u znakovnom nizu – metoda `replace`

```
>>> S = 'spammy'
>>> S = S.replace('mm', 'xx')
>>> S
'spaxxy'
```

- metoda `replace` obavlja *globalnu* zamjenu

```
>>> 'aa$bb$cc$dd'.replace('$', 'SPAM')
'aaSPAMbbSPAMccSPAMdd'
```

Metode znakovnih nizova (2)

- zamjena prve pojave podniza

```
>>> S = 'xxxxSPAMxxxxSPAMxxxx'
>>> where = S.find('SPAM') # Search for position
>>> where  # Occurs at offset 4
4
>>> S = S[:where] + 'EGGS' + S[(where+4):]
>>> S
'xxxxEGGSxxxxSPAMxxxx'
```

  - metoda `find` vraća indeks na kojem započinje traženi podniz, ili `-1` ako podniz nije pronađen

- jednostruka zamjena može se postići metodom `replace`, uz dodavanje trećeg argumenta (broj zamjena)

```
>>> S.replace('SPAM', 'EGGS', 1) # Replace one
'xxxxEGGSxxxxSPAMxxxx'
```

  - još jednom: *stvara se novi string*!

Metode znakovnih nizova (3)

- ako se primjenjuje veći broj uzastopnih operacija nad dugačkim znakovnim nizovima, nezgodno je što svaka operacija generira *novi* niz
  - ponekad se isplati pretvoriti string u izmjenljivi objekt – *listu*, kako bi se operacije obavljale na licu mjesta
  - ugrađena funkcija `list` (zapravo konstruktor liste) – formira novu listu na temelju objekta koji joj se predaje kao argument

```
>>> S = 'spammy'
>>> L = list(S)
>>> L
['s', 'p', 'a', 'm', 'm', 'y']

>>> L[3] = 'x' # radi s listama, ne sa stringovima
>>> L[4] = 'x'
>>> L
['s', 'p', 'a', 'x', 'x', 'y']
```

Metode znakovnih nizova (4)

- nakon obavljenih izmjena, listu možemo “spakirati” nazad u string primjenom metode `join`

```
>>> S = ''.join(L) # "uvlaci" listu u string
>>> S
'spaxxy'
```

- `join` je metoda znakovnih nizova, a poziva se preko željenog graničnika
  - znakovni nizovi iz liste povezuju se u jedan niz, pri čemu se između njih umeće niz koji je naveden kao graničnik

```
>>> 'SPAM'.join(['eggs', 'sausage', 'ham', 'toast'])
'eggsSPAMsausageSPAMhamSPAMtoast'
```

Metode znakovnih nizova (5)

- ako su podaci u znakovnom nizu poznate širine polja, lako ih je izrezati

```
>>> line = 'aaa bbb ccc'
>>> podatak1 = line[0:3]
>>> podatak3 = line[8:]
```

- ako su polja odvojena graničnikom, primjenjuje se metoda `split` – rezultat je lista podnizova
  - ako se ne proslijedi argument, dijeljenje se obavlja ne prazninama (jedan ili više praznih znakova, tabova, prelezaka u novi red)

```
>>> line = 'aaa bbb ccc'
>>> cols = line.split( )
>>> cols
['aaa', 'bbb', 'ccc']
```

Metode znakovnih nizova (6)

- metoda `split`
  - ako se kao argument navede znakovni niz, on se koristi kao graničnik

```
>>> line = 'bob,hacker,40'
>>> line.split(',')
['bob', 'hacker', '40']

>>> line = "i'mSPAMaSPAMlumberjack"
>>> line.split("SPAM")
["i'm", 'a', 'lumberjack']
```

- izrezivanje i `split` rade vrlo brzo, obavljaju osnovnu ekstrakciju teksta
- mnoštvo drugih metoda nad stringovima
- metode *ne prihvaćaju* regularne izraze
  - koristi se modul `re` iz standardne biblioteke

Liste

- liste su fleksibilne uređene kolekcije
- za razliku od stringova, liste mogu sadržavati bilo koju vrstu objekata, pa i druge liste
  - definirano je uređenje, pristup elementu liste putem indeksa
  - podržano je izrezivanje i nadovezivanje
  - duljina se može mijenjati (umetanje i brisanje objekata)
  - elementi su proizvoljni objekti – heterogenost
  - proizvoljno gniježdenje
  - liste u Pythonu sadrže 0 ili više *referenci* na objekte
    - slično polju pokazivača u C-u
    - dohvat elementa Python liste je brzo gotovo kao indeksiranje polja u C-u
    - zapravo su liste i ostvarene kao C polja unutar Python interpretera
    - kada se umeće objekt u listu, pohranjuje se referenca, a ne kopija objekta

Operacije nad listama

- tablica – liste: literali i (neke) operacije

Operacija	Opis
`L1 = [ ]`	prazna lista
`L2 = [0, 1, 2, 3]`	četiri elementa, indeksi 0..3
`L3 = ['abc', ['def', 'ghi']]`	ugniježdena podlista
`L2[i] ; L3[i][j]`	indeksiranje
`L2[i:j] ; len(L2)`	izrezivanje, određivanje duljine
`L1 + L2 ; L2 * 3`	ulančavanje, ponavljanje
`for x in L2 ; 3 in L2`	iteriranje, pripadnost
`L2.append(4) ; L2.extend([5,6,7])`	metode: dodavanje elemenata
`L2.sort( ) ; L2.index(1) ; L2.reverse( )`	sortiranje, pretraživanje,...
`del L2[k] ; del L2[i:j] ;` `L2.pop( ) ; L2[i:j] = [ ]`	brisanje
`L2[i] = 1 ; L2[i:j] = [4,5,6]`	pridruživanje vrijednosti

Operacije nad listama (2)

- na liste se primjenjuju operacije nadovezivanja ("+") i ponavljanja ("*"), slično kao kod znakovnih nizova (općenito – operacije nad sekvencama)
  - rezultat je nova lista

```
>>> len([1, 2, 3])
3

>>> [1, 2, 3] + [4, 5, 6]
[1, 2, 3, 4, 5, 6]

>>> ['Ni!'] * 4
['Ni!', 'Ni!', 'Ni!', 'Ni!']

>>> 3 in [1, 2, 3] # pripadnost (True)
True

>>> for x in [1, 2, 3]: print x, # Iteration
...
1 2 3
```

Operacije nad listama (3)

- iako ulančavanja djeluje na liste i na stringove, očekuje se isti tip sekvence na obje strane operatora – inače greška
  - ne možemo ulančavati listu sa znakovnim nizom, osim ako najprije pretvorimo listu u znakovni niz (pomoću obrnutih navodnika, funkcije `str` ili `%` formatiranja); ili znakovni niz u listu

```
>>> L=[1, 2]
>>> ‘L‘ + "34" # kao "[1, 2]" + "34"
’[1, 2]34’

>>> [1, 2] + list("34") # kao [1, 2] + ["3", "4"]
[1, 2, ’3’, ’4’]
```

Indeksiranje i izrezivanje

- indeksiranje i izrezivanje radi na listama kao i na znakovnim nizovima
  - indeksiranje vraća (kopiju) objekta koji se nalazi u listi na mjestu na koje indeks pokazuje
  - izrezivanje vraća novu listu

```
>>> L = ['spam', 'Spam', 'SPAM!']
>>> L[2] # indeksi krecu od 0
'SPAM!'

>>> L[-2] # negativni indeks - odbrojavanje od kraja
'Spam'

>>> L[1:]
['Spam', 'SPAM!']
```

Matrice

- jedan od načina za prikaz matrica (višedimenzionlanih polja) u Pythonu je gniježdenjem listi – npr. matrica 3×3

```
>>> matrix = [[1, 2, 3], [4, 5, 6], [7, 8, 9]]
```

- primjenom jednog indeksa dobivamo cijeli redak matrice (ugniježdenu listu), s dva indeksa dohvaćamo jedan element

```
>>> matrix[1]
[4, 5, 6]

>>> matrix[1][1]
5

>>> matrix[2][0]
7

>>> matrix = [[1, 2, 3],
...           [4, 5, 6],
...           [7, 8, 9]]

>>> matrix[1][1]
5
```

Izmjena liste

- liste su izmjenljivi objekti – mogu se mijenjati na licu mjesta, bez stvaranja kopije
- kako Python radi s referencama, izmjena objekta utječe i na druge reference na taj objekt !
- sadržaj liste može se izmijeniti pridjeljivanjem vrijednosti pojedinom elementu, ili cijelom isječku (*slice*)

```
>>> L = ['spam', 'Spam', 'SPAM!']
>>> L[1] = 'eggs' # Index assignment
>>> L
['spam', 'eggs', 'SPAM!']

>>> L[0:2] = ['eat', 'more'] # Slice assignment
>>> L
['eat', 'more', 'SPAM!']
```

Izmjena liste (2)

- pridjeljivanje vrijednosti isječku ponaša se *kao* brisanje i umetanje (broj elemenata koji se umeće ne mora odgovarati broju elemenata koji se brišu)

```
>>> L = [1, 2, 3]
>>> L[1:2]=[4,5]
>>> L
[1, 4, 5, 3]

>>> L[1:3]=[ ] # brisanje elemenata
>>> L
[1, 3]
```

- funkcionira i u slučaju preklapanja isječka s vrijednostima i isječka kojem se dodjeljuju vrijednosti

```
>>> L = [1, 2, 3, 4, 5, 6, 7, 8]
>>> L[2:5]=L[3:6]
>>> L
[1, 2, 4, 5, 6, 6, 7, 8]
```

Metode listi

- liste imaju specifične *metode*
- primjeri

```
>>> L.append('please') # dodavanje jednog elementa
>>> L
['eat', 'more', 'SPAM!', 'please']
>>> L.sort( ) # sortiranje ('S' < 'e').
>>> L
['SPAM!', 'eat', 'more', 'please']
```

  - metoda `append` prima samo jedan objekt, koji se nadodaje na kraj liste
  - efekt izraza `L.append(X)` je sličan kao `L+[X]`, ali drugi izraz stvara *novu* listu – `append` je obično brže
  - obje metode mijenjaju listu na licu mjesta, ali *ne vraćaju listu kao rezultat*
    `L=L.append(X)` će *obrisati* referencu na listu !

Metode listi (2)

- još primjera

```
>>> L = [1, 2]
>>> L.extend([3,4,5]) # dodavanje liste elemenata
>>> L
[1, 2, 3, 4, 5]

>>> L.pop( ) # brise i vraca zadnji element
5
>>> L
[1, 2, 3, 4]

>>> L.reverse( ) # promjena redoslijeda
>>> L
[4, 3, 2, 1]
```

Metode listi (3)

- korištenjem metoda `pop` i `append` lako je implementirati brzu stogovnu strukturu (kraj liste je vrh stoga)

```
>>> L = [ ]
>>> L.append(1) # Push
>>> L.append(2)
>>> L
[1, 2]
>>> L.pop( )  # Pop
2
>>> L
[1]
```

- `pop` se može koristiti i s indeksom – briše se proizvoljni element

```
>>> L = [1, 2, 3, 4, 5]
>>> L.pop(3)
4
>>> L
[1, 2, 3, 5]
```

Metode listi (4)

- za brisanje elementa ili dijela liste može se primijeniti naredba `del`

```
>>> L
['SPAM!', 'eat', 'more', 'please']
>>> del L[0] # brisanje jednog elementa
>>> L
['eat', 'more', 'please']

>>> del L[1:] # brisanje isjecka
>>> L
['eat']
```

- dijelovi liste mogu se obrisati i operacijom pridruživanja isječku

```
>>> L = ['Already', 'got', 'one']
>>> L[1:] = [ ]
>>> L
['Already']
```

- pridjeljivanje prazne liste indeksiranjem pohranjuje u indeksirani element referencu na praznu listu !

Rječnici

- uz liste, najfleksibilniji ugrađeni tip u Pythonu
- neuređena kolekcija objekata
- elementi se dohvaćaju i pohranjuju na temelju *ključa*
  - indeksiranje u rječniku je vrlo brza operacija pretraživanja
  - asocijativno polje (*hash*)
  - elementi nisu složeni u određenom redosljedu, ključevi određuju simboličko mjesto elemenata u rječniku
  - Python koristi optimirane *hashing* algoritme, pa su dohvati vrlo brzi
- duljina rječnika je varijabilna, elementi su proizvoljnih tipova
- mogu sadržavati liste i rječnike (gniježdenje proizvoljne dubine)
- poput lista – izmjenljivi objekti
  - kako nisu uređeni, ne podupiru operacije nad sekvencama
  - rječnici sadrže *reference* na objekte, kao i liste

Operacije nad rječnicima

- tablica – rječnici: literali i (neke) operacije

Operacija	Opis
`D1 = { }`	prazni rječnik
`D2 = {'spam': 2, 'eggs': 3}`	rječnik s dva elementa
`D3 = {'food': {'ham': 1, 'egg': 2}}`	gniježdenje
`D2['eggs'] ; d3['food']['ham']`	indeksiranje ključem

`D2.has_key('eggs'); 'eggs' in D2`
`D2.keys( ) ; D2.values( )`
`D2.copy( ) ; D2.get(key, default)`
	metode: pripadnost
	ključevi, vrijednosti
	kopiranje ...

`len(d1)`	duljina (ukupni broj elemenata)
`D2[key] = 42 ; del d2[key]`	dodavanje/izmjena; brisanje

Operacije nad rječnicima (2)

- stvaranje rječnika i pristup elementima (vrijednostima)

```
>>> d2 = {'spam': 2, 'ham': 1, 'eggs': 3}
>>> d2['spam'] # dohvat vrijednosti na temelju kljuca
2
>>> d2 # redoslijed je nepredvidljiv
{'eggs': 3, 'ham': 1, 'spam': 2}
```

- redoslijed elemenata je različit od onog kojim su elementi uneseni – zbog implementacije brzog dohvata (*hashing*)
  - operacije nad sekvencama (izrezivanje, nadovezivanje) ne mogu se primjenjivati na rječnicima
- ugrađena funkcija `len()` primjenjiva je na rječnike – vraća broj pohranjenih elemenata

```
>>> len(d2)
3
```

Metode rječnika

- metoda `has_key()` omogućuje ispitivanje postojanja zadanog ključa

```
>>> d2.has_key('ham') # postojanje kljuca
True
>>> 'ham' in d2 # drugi nacin - pripadnost
True
```

- metoda `keys()` vraća listu svih ključeva rječnika

```
>>> d2.keys( )
['eggs', 'ham', 'spam']
```

Izmjene rječnika

- rječnici su izmjenljivi (*mutable*) objekti
  - mogu se mijenjati, proširivati ili smanjivati bez stvaranja kopije

```
>>> d2['ham'] = ['grill', 'bake', 'fry'] # izmjena elementa
>>> d2
{'eggs': 3, 'spam': 2, 'ham': ['grill', 'bake', 'fry']}

>>> del d2['eggs'] # brisanje elementa
>>> d2
{'spam': 2, 'ham': ['grill', 'bake', 'fry']}

>>> d2['brunch'] = 'Bacon' # dodavanje elementa
>>> d2
{'brunch': 'Bacon', 'spam': 2, 'ham': ['grill', 'bake', 'fry']}
```

Izmjene rječnika (2)

- kao i kod listi, dodjela vrijednosti preko postojećeg ključa mijenja vrijednost elementa rječnika
- ako dodjeljujemo vrijednost za nepostojeći ključ, stvara se novi element rječnika
  - *kod liste pokušaj dodjele vrijednosti preko nepostojećeg indeksa uzrokuje grešku*
  - dodavanje novog elementa u listu moguće je pomoću metode `append()` ili dodjelom vrijednosti isječku

Još neke metode

- rječnici imaju različite korisne metode
- metoda `values()` vraća listu vrijednosti elemenata rječnika

```
>>> d2.values()
[3, 1, 2]
```

- metoda `items()` vraća listu parova `(ključ, vrijednost)`

```
>>> d2.items()
[('eggs', 3), ('ham', 1), ('spam', 2)]
```

- pokušaj dohvata preko nepostojećeg ključa rezultira greškom, no može se koristiti metoda `get()` koja u tom slučaju vraća pretpostavljenu vrijednost (`None` ili pretpostavljenu vrijednost koja se prosljeđuje kao argument)

```
>>> d2.get('ham'), d2.get('salt'), d2.get('salt', 8)
(1, None, 8)
```

Još neke metode (2)

- metoda `update()` nudi funkcionalnost sličnu ulančavanju – ključevi i vrijednosti jednog rječnika spajaju se s drugim rječnikom
  - vrijednosti s istim ključem se pritom *prepisuju*

```
>>> d2 = {'eggs':3, 'ham':1, 'spam':2}
>>> d3 = {'toast':4, 'muffin':5, 'eggs':7}
>>> d2.update(d3)
>>> d2
{'toast': 4, 'ham': 1, 'spam': 2, 'muffin': 5,
'eggs': 7}
```

- metoda `pop()` briše element iz rječnika i vraća njegovu vrijednost

```
>>> d2 = {'toast':4, 'eggs':3, 'ham':1, 'spam':2}
>>> d2.pop('toast')
4
>>> d2
{'eggs': 3, 'ham': 1, 'spam': 2}
```

Primjer

- primjer – podaci o autorima skriptnih jezika

```
>>> table = {'Python': 'Guido van Rossum',
...          'Perl': 'Larry Wall',
...          'Tcl':  'John Ousterhout' }
>>> language = 'Python'
>>> creator = table[language]
>>> creator
'Guido van Rossum'

>>> for lang in table.keys( ):
...     print lang, '\t', table[lang]
...
Tcl      John Ousterhout
Python   Guido van Rossum
Perl     Larry Wall
```

Rječnik kao fleksibilna "lista"

- ključ ne mora biti string – može biti bilo koji nepromjenljivi tip, npr. cijeli broj
- pridruživanje vrijednosti nepostojećem elementu liste nije dozvoljeno

```
>>> L = [ ]
>>> L[99] = 'spam'
Traceback (most recent call last):
  File "<stdin>", line 1, in ?
IndexError: list assignment index out of range
```

- mogli bismo alocirati veliku listu primjenom operatora ponavljanja: npr. `L = [0]*100`, ali nešto slično možemo postići rječnikom

Rječnik kao fleksibilna "lista" (2)

- korištenjem cjelobrojnog ključa možemo oponašati listu koja raste prema potrebi

```
>>> D = { }
>>> D[99] = 'spam'
>>> D[99]
'spam'
>>> D
{99: 'spam'}
```

  - izgleda kao lista od 100 elemenata, a zapravo je rječnik s jednim elementom

Pohrana rijetkih podatkovnih struktura

- rječnik je prikladan za pohranu rijetkih matrica – samo mali broj elemenata ima vrijednost

```
>>> Matrix = { }
>>> Matrix[(2,3,4)] = 88
>>> Matrix[(7,8,9)] = 99

>>> X = 2; Y = 3; Z = 4 # ; odvaja naredbe
>>> Matrix[(X,Y,Z)]
88
>>> Matrix
{(2, 3, 4): 88, (7, 8, 9): 99}
```

  - koristimo rječnik za prikaz trodimenzionalnog polja
  - ključevi su trojke (*tuples*), čiji su elementi koordinate elementa
  - samo su dva elementa popunjena, nije nam potrebna velika 3D matrica
  - pristup nedefiniranim "elementima" uzrokuje pogrešku (nepostojeći ključ)

Pohrana rijetkih podatkovnih struktura (2)

- pristup nedefiniranim "elementima" uzrokuje pogrešku (nepostojeći ključ) – više rješenja
  - provjera postojanja ključa

```
if Matrix.has_key((2,3,6)): # provjera kljuca
    print Matrix[(2,3,6)]
else:
    print 0
```

  - korištenjem naredbe `try` (hvatanje iznimke)

```
try:
   print Matrix[(2,3,6)] # Try to index
except KeyError:         # Catch and recover
   print 0
```

  - najjednostavnije – metoda `get()`

```
>>> Matrix.get((2,3,4), 0) # postoji
88
>>> Matrix.get((2,3,6), 0) # ne postoji
0
```

n-torke

- *n*-torka (*tuple*) je uređena kolekcija (kao i lista) proizvoljnih objekata, koja *nije izmjenljiva*
  - ponaša se jednako kao i lista, jedino se ne može mijenjati na licu mjesta
  - ne podržava pozive metoda
- zašto uopće i liste i n-torke ?
  - nepromjenljivost daje određenu dozu *integriteta* – možemo biti sigurni da n-torka neće biti promijenjena preko neke druge reference u programu
  - n-torke se mogu koristiti u nekim situacijama u kojima liste ne mogu – npr. kao ključevi rječnika

Uobičajene operacije

- tablica – n-torke: literali i uobičajene operacije

Operacija	Opis
`( )`	prazna n-torka
`t1 = (0,)`	jednočlana n-torka (!)
`t2 = (0, 'Ni', 1.2, 3)`	četveročlana n-torka
`t2 = 0, 'Ni', 1.2, 3`	može i ovako
`t3 = ('abc', ('def', 'ghi'))`	ugniježdene n-torke
`t1[i] ; t3[i][j]`	indeksiranje
`t1[i:j] ; len(t1)`	izrezivanje, duljina
`t1 + t2 ; t2 * 3`	ulančavanje, ponavljanje
`for x in t2 ; 3 in t2`	iteracija, pripadnost

Operacije s n-torkama

- standardne operacije

```
>>> (1, 2) + (3, 4) # nadovezivanje
(1, 2, 3, 4)

>>> (1, 2) * 4 # ponavljanje
(1, 2, 1, 2, 1, 2, 1, 2)

>>> T = (1, 2, 3, 4)
>>> T[0], T[1:3] # indexing, slicing
(1, (2, 3))
```

- n-torku s jednim elementom ne možemo napisati kao `t = (1)` jer će to Python shvatiti kao izraz, tj. kao `t = 1`
  - zato jednočlanu n-torku zapisujemo s dodanim zarezom

```
>>> y = (40,)
>>> y
(40,)
```

Operacije s n-torkama (2)

- n-torke ne podržavaju metode !
- npr. ako hoćemo sortirati n-torku, obično ćemo je najprije pretvoriti u listu

```
>>> T = ('cc', 'aa', 'dd', 'bb')
>>> tmp = list(T)
>>> tmp.sort( )
>>> tmp
['aa', 'bb', 'cc', 'dd']
>>> T = tuple(tmp)
>>> T
('aa', 'bb', 'cc', 'dd')
```

  - ugrađene funkcije za pretvorbu `list()` i `tuple()`
  - obje funkcije vraćaju nove objekte

Operacije s n-torkama (3)

- pravilo o nepromjenljivosti n-torki odnosi se samo na najvišu razinu same n-torke
  - n-torka može sadržavati druge, izmjenljive objekte, npr. liste

```
>>> T = (1, [2, 3], 4)
>>> T[1][0] = 'spam' # Works
>>> T
(1, ['spam', 3], 4)
>>> T[1] = 'spam'    # Fails
TypeError: object doesn't support item assignment
```

Datoteke

- datoteke – imenovani spremnici na računalu, kojima upravlja operacijski sustav
- datoteke (*files*) kao ugrađeni tip podataka u Pythonu omogućuju pristup datotekama
  - ugrađena funkcija `open()` stvara Python objekt tipa `file` koji služi kao veza prema fizičkoj datoteci
  - čitanje i pisanje u datoteku ostvaruje se pozivanjem metoda datotečnog objekta
  - ugrađeno ime `file` je sinonim za `open`

Operacije s datotekama

- tablica – uobičajene operacije s datotekama

Operacija	Opis
`out = open('/tmp/spam', 'w')`	otvara datoteku za pisanje
`in = open('data', 'r')`	otvara datoteku za čitanje
`S = in.read( )`	učitava cijelu datoteku u string
`S = in.read(N)`	čita N bajtova
`S = in.readline( )`	učitava sljedeći redak
`L = in.readlines( )`	cijelu datoteku u listu stringova L
`out.write(S)`	zapisuje string
`out.writelines(L)`	zapisuje stringove iz liste L
`out.close( )`	zatvaranje datoteke

Operacije s datotekama (2)

- otvaranje datoteke funkcijom `open()`
  - navodi se ime datoteke i način pristupa (čitanje, pisanje, nadodavanje)
  - argumenti su stringovi
  - ime datoteke može sadržavati apsolutni ili relativni put
  - ako se put ne navede, datoteka se traži u tekućem kazalu (gdje je skripta pokrenuta)
- učitavanje i zapisivanje podataka – u obliku znakovnih nizova
- zatvaranje datoteke – metodom `close()`
  - zahvaljujući mehanizmu prikupljanja otpada, Python automatski zatvara datoteku kada se oslobađa nereferencirani objekt tipa `file`
  - nije nužno “ručno” zatvarati datoteke, osobito u kratkim skriptama
  - ipak je zatvaranje datoteka dobra navika u većim projektima

Operacije s datotekama (3)

- primjer

```
>>> myfile = open('myfile', 'w') # otvara za pisanje
>>> myfile.write('hello text file\n')
>>> myfile.close( )

>>> myfile = open('myfile', 'r') # otvara za citanje
>>> myfile.readline( )
'hello text file\n'
>>> myfile.readline( ) # prazni string: EOF
''
```

- kraj datoteke signalizira prazni string – čitanje praznog retka daje `'\n'`
- prilikom otvaranja datoteke, uz način pristupa može se dodati oznaka `'b'` – binarni pristup (bez pretvorbi oznake kraja retka)
- dodavanje oznake `'+'` omogućuje otvaranje datoteke za čitanje i pisanje

Operacije s datotekama (4)

- objekte koje želimo zapisati nužno je pretvoriti u znakovne nizove – metode za učitavanje i zapisivanje ne obavljaju automatski pretvorbu

```
>>> X, Y, Z = 43, 44, 45 # razni tipovi objekata
>>> S = 'Spam'           # moraju se pretvoriti
>>> D = {'a': 1, 'b': 2}
>>> L = [1, 2, 3]

>>> F = open('datafile.txt', 'w')
>>> F.write(S + '\n') # kraj retka \n
>>> F.write('%s,%s,%s\n' % (X, Y, Z)) # pretvorba
>>> F.write(str(L) + '$' + str(D) + '\n')
>>> F.close( )

>>> bytes = open('datafile.txt').read( )
>>> bytes
"Spam\n43,44,45\n[1, 2, 3]${'a': 1, 'b': 2}\n"
```

Operacije s datotekama (5)

- nakon učitavanja, znakovne nizove je potrebno pretvoriti nazad u objekte

```
>>> F = open('datafile.txt')
>>> line = F.readline( )
>>> line
'Spam\n'
>>> line.rstrip( ) # Remove end-of-line
'Spam'

>>> line = F.readline( ) # sljedeci redak
>>> line
'43,44,45\n'
>>> parts = line.split(',') # dijelimo na zarezima
>>> parts
['43', '44', '45\n']

>>> numbers = [int(P) for P in parts] # int liste
>>> numbers # int zanemaruje \n
[43, 44, 45]
```

Operacije s datotekama (6)

- nastavak – lista i rječnik
- za pretvorbu ćemo iskoristiti ugrađenu funkciju `eval`, koja koristi znakovni niz kao Python izraz (izvršivi kôd)

```
>>> line = F.readline( )
>>> line
"[1, 2, 3]${'a': 1, 'b': 2}\n"
>>> parts = line.split('$') # dijeli na $
>>> parts
['[1, 2, 3]', "{'a': 1, 'b': 2}\n"]
>>> eval(parts[0])
[1, 2, 3]
>>> objects = [eval(P) for P in parts] # lista
>>> objects
[[1, 2, 3], {'a': 1, 'b': 2}]
```

Pohranjivanje Python objekata

- ugrađena funkcija `eval` je moćna, može se čak reći “previše moćna” !
- izrvršit će *svaki* Python kôd učitan iz datoteke (pa i onaj *štetni*)
- za pohranu i učitavanje Python objekata vrlo je prikladan standardni modul `pickle`

```
>>> F = open('datafile.txt', 'w')
>>> import pickle
>>> pickle.dump(D, F) # D je dictionary
>>> F.close( )

>>> F = open('datafile.txt')
>>> E = pickle.load(F) # Load any object
>>> E
{'a': 1, 'b': 2}
```

Usporedbe

- objekti u Pythonu mogu se uspoređivati
  - uspoređuju se svi dijelovi složenih objekata, do trenutka kada se može odlučiti o odnosu uspoređivanih objekata
  - ugniježdeni objekti uspoređuju se rekurzivno, do potrebne dubine – prva pronađena razlika određuje rezultat usporedbe

```
>>> L1 = [1, ('a', 3)] # ista vrijednost
>>> L2 = [1, ('a', 3)] # razliciti objekti
>>> L1 == L2, L1 is L2 # jednaki? isti?
(True, False)
```

- operator `==` ispituje jednakost objekata, a operator `is` njihov identitet (nalaze li se objekti na istoj adresi u memoriji)

Usporedbe (2)

- zanimljivo je pogledati što se događa npr. s *kratkim* stringovima (slično je i s brojevima):

```
>>> S1 = 'spam'
>>> S2 = 'spam'
>>> S1 == S2, S1 is S2
(True, True)
```

  - očekivali bismo dva različita objekta iste vrijednosti, no oba imena referenciraju *isti* objekt
  - razlog je interna optimizacija koju Python primjenjuje

- za dulje stringove to se ne događa

```
>>> S1 = 'malo dulji string'
>>> S2 = 'malo dulji string'
>>> S1 == S2, S1 is S2
(True, False)
```

- zbog nepromjenljivosti stringova i brojeva – nema utjecaja na ponašanje programa

Usporedbe (3)

- usporedba veličine objekata obavlja se rekurzivno nad ugniježdenim strukturama podataka

```
>>> L1 = [1, ('a', 3)]
>>> L2 = [1, ('a', 2)]
>>> L1 < L2, L1 == L2, L1 > L2
(False, False, True)
```

- općenito, usporedbe u Pythonu se obavljaju:
  - brojevi se uspoređuju po veličini
  - znakovni nizovi se uspoređuju leksikografski (`"abc" < "ac"`)
  - liste se uspoređuju komponentu po komponentu, s lijeva udesno
  - rječnici se uspoređuju kao sortirane liste parova `(ključ, vrijednost)`
- vrijednosti istinitosti u Pythonu
  - brojevi su `true` ako su različiti od 0
  - ostali objekti su `true` ako su *neprazni*

Naredbe u Pythonu

- do sada smo susretali jednostavne *izraze*, te naredbe pridruživanja vrijednosti (*assignment*)
- složene naredbe (*compound statements*) u Pythonu imaju specifičnu strukturu
  - primjer – naredba `if`
  - oblik u C-u (C++, Java, JavaScript, Perl)

```
if (x > y) {
    x = 1;
    y = 2;
}
```

  - oblik u Pythonu:

```
if x > y:
    x = 1
    y = 2
```

Naredbe u Pythonu (2)

- oblik naredbe u Pythonu:

```
if x > y:  # header line
   x = 1   # nested block
   y = 2
```

  - nema oznaka početka i kraja bloka
    – blok naredbi određuje *uvlačenje* kôda
    – sve naredbe bloka moraju biti jednako uvučene
  - dvotočka na kraju zaglavlja je *obavezna* – jedna od najčešćih pogrešaka kod početnika :-)
  - zagrade oko uvjeta koji se ispituje su *neobavezne* – mogu se pisati, ali nije Pythonski stil
  - kraj retka je kraj naredbe – nema potrebe za `";"`
  - u jedan redak možemo “ugurati” više *jednostavnih* naredbi

```
a = 1; b = 2; print a + b
```

Naredbe u Pythonu (3)

- pojedinu naredbu možemo “razvući” na više redaka
  - ako dio naredbe uključuje par zagrada (oblih, uglatih ili vitičastih) – naredba ne može završiti dok se ne dođe do zatvarajuće zagrade

```
mlist = [111,
         222,
         333]
```

  - kako se bilo koji izraz može zatvoriti u zagrade, na taj način je lako ostvariti “dozvolu” prelaska naredbe u novi red

```
X = (A + B +
     C + D)
```

  - funkcionira i za složene naredbe

```
if (A == 1 and
    B == 2 and
    C == 3):
        print 'spam' * 3
```

Naredbe u Pythonu (4)

- pisanje naredbe kroz više redaka moguće je i označavanjem nastavljanja znakom `"\"`

```
X = A + B + \
      C + D
```

  - zastarjelo, nepopularno u “Pythonlandu”
  - teško je uočiti `"\"`, ne smije biti praznina nakon oznake
- još jedan izuzetak – složene naredbe u jednom retku

```
if x > y: print x
```

  - dozvoljeno pisanje naredbi `if`, ili kratkih petlji u jednom retku
  - najčešća primjena – prijevremeni izlazak iz petlje (`break`)

Naredba `if`

- naredba `if` – tipična za većinu proceduralnih jezika
- općeniti oblik:

```
if <test1>:
    <statements1> #blok naredbi
elif <test2>:   # opcionalni elif
    <statements2>
else:           # opcionalni else
    <statements3>
```

- Python izvršava blok naredbi pridružen prvom uvjetu koji je ispunjen (`true`), ili blok naredbi pridružen grani `else` ukoliko niti jedan od uvjeta nije ispunjen
- dijelovi `elif` i `else` mogu se izostaviti
- vezanje dijelova iste naredbe: `if`, `elif` i `else` određuje se njihovim vertikalnim poravnavanjem !

Naredba `if` (2)

- primjer

```
>>> x = 'killer rabbit'
>>> if x == 'roger':
...   print "how's jessica?"
... elif x == 'bugs':
...   print "what's up doc?"
... else:
...   print 'Run away! Run away!'
...
Run away! Run away!
```

Višestruko grananje

- Python nema naredbu oblika `switch` ili `case`, već se izvodi nizom `if-elif` ispitivanja ili indeksiranjem rječnika
  - kako se rječnici mogu graditi tijekom izvođenja programa, taj način upravljanja programskim slijedom može biti fleksibilniji od unaprijed kodiranih grananja

```
>>> choice = 'ham'
>>> branch = {'spam': 1.25,
...           'ham': 1.99,
...           'eggs': 0.99}
>>> print branch.get(choice, 'Bad choice') # default
1.99
>>> print branch.get('bacon', 'Bad choice')
```

- rječnici su prikladni za ovakvu vrstu akcija, no mogu se primijeniti i za složenije situacije – rječnici mogu sadržavati i funkcije

Programska petlja `while`

- najopćenitija naredba programske petlje
  - izvršava se blok naredbi dok god je uvjet ispunjen
  - ako uvjet već na početku nije ispunjen, tijelo petlje se ne izvrši niti jednom
- općeniti oblik naredbe:

```
while <test>:          # uvjet
    <statements1> #tijelo
else:                  # opcionalno
    <statements2> #ako nije zavrsena s break
```

- dio `else` je opcionalan, a izvršava se ukoliko petlja nije prekinuta naredbom `break`
  - specifičnost Pythona

Programska petlja `while` (2)

- primjeri

```
>>> while 1: # beskonacna petlja
...   print 'Type Ctrl-C to stop me'!

>>> x = 'spam'
>>> while x: # dok je niz neprazan
...    print x,
...    x = x[1:] # odrezuje prvi znak
...
spam pam am m

>>> a=0; b=10
>>> while a < b: # petlja brojalica
...    print a,
...    a += 1 # isto kao a = a+1
...
0 1 2 3 4 5 6 7 8 9
```

Naredbe `break` i `continue`

- naredbe `break` i `continue` imaju smisla samo unutar programskih petlji
  - `break` uzrokuje izlazak iz (najbliže) petlje unutar koje se nalazi
  - `continue` uzrokuje prelazak na sljedeću iteraciju petlje u kojoj se nalazi, odnosno premještanje izvođenja na zaglavlje petlje
  - naredba `pass` je *prazna* naredba – ne radi ništa; koristi se na mjestima gdje sintaksa zahtijeva naredbu, a nemamo ništa "pametno za raditi"
  - blok `else` u petlji izvršava se u slučaju *normalnog* završetka petlje (bez nailaska na naredbu `break`)
- oblik petlje uključujući `break` i `continue`

```
while <test1>:
    <statements1>
    if <test2>: break #izlaz
    if <test3>: continue #na pocetak
else:
    <statements2> #ako nije bio break
```

Naredbe `break` i `continue` (2)

- primjeri

```
while 1: pass # Type Ctrl-C to stop me!
```

```
x = 10
while x:
    x = x-1 # ili x -= 1
    if x % 2 != 0: continue # preskoci neparan
    print x,
```

```
>>> while 1:
...     name = raw_input('Enter name: ')
...     if name == 'stop': break
...     age = raw_input('Enter age: ')
...     print 'Hello', name, '=>', int(age) ** 2
...
Enter name: mel
Enter age: 40
Hello mel => 1600
Enter name: stop
```

Programska petlja `for`

- petlja `for` je namijenjena *iteriranju* kroz sekvence – funkcionira za znakovne nizove, liste i n-torke, ali i za odgovarajuće oblikovane korisničke objekte
- oblik naredbe:

```
for <target> in <object>: #elementi objekta
    <statements> #tijelo petlje
else:
    <statements> #ako nije bio break
```

  - varijabli petlje pridjeljuje se vrijednost jednog po jednog elementa sekvence, i za svaki se izvršava blok naredbi
  - i petlja `for` podržava opcionalnu granu `else`, koja se izvršava pri normalnom (neprekinutom) završetku petlje
  - mogu se koristiti i naredbe `break` i `continue`

Programska petlja `for` (2)

- primjeri

```
>>> for x in ["spam", "eggs", "ham"]:
...     print x,
...
spam eggs ham

>>> sum = 0
>>> for x in [1, 2, 3, 4]:
...     sum = sum + x
...
>>> sum
10

>>> prod = 1
>>> for item in [1, 2, 3, 4]: prod *= item
...
>>> prod
24
```

Programska petlja `for` (3)

- petlja `for` može se primijeniti i sa stringovima i n-torkama

```
>>> S, T = "lumberjack", ("and", "I'm", "okay")
>>> for x in S: print x,
...
l u m b e r j a c k
>>> for x in T: print x,
...
and I'm okay
```

- ako se prolazi kroz sekvencu n-torki, varijabla petlje može biti n-torka varijabli

```
>>> T = [(1, 2), (3, 4), (5, 6)]
>>> for (a, b) in T: # tuple assignment
...   print a, b
...
1 2
3 4
5 6
```

Programska petlja `for` (4)

- primjer ugniježdenih petlji

```
>>> items = ["aaa", 111, (4, 5), 2.01] # skup objekat
>>> tests = [(4, 5), 3.14] # elementi koje trazimo
>>>
>>> for key in tests: # za svaki kljuc
...     for item in items: # za svaki objekt
...         if item == key: # provjera podudaranja
...             print key, "was found"
...             break
...     else:
...         print key, "not found"
...
(4, 5) was found
3.14 not found
```

Programska petlja `for` (4)

- isti primjer, elegantnije rješenje

```
>>> for key in tests: # For all keys
...     if key in items: # Let Python check for a match
...         print key, "was found"
...     else:
...         print key, "not found"
...
(4, 5) was found
3.14 not found
```

  - u ovom primjeru koristi se operator `in` kako bi ispitao pripadnost – on implicitno prolazi kroz listu tražeći podudaranje i tako zamjenjuje unutrašnju petlju
  - općenito – dobro je prepustiti Pythonu da obavi čim veći dio posla, kako zbog jezgrovitosti kôda, tako i zbog performanse

Funkcija `range`

- ugrađena funkcija `range` generira listu cijelih brojeva

```
>>> range(5), range(2, 5), range(0, 10, 2)
([0, 1, 2, 3, 4], [2, 3, 4], [0, 2, 4, 6, 8])
```

  - s jednim argumentom `range` generira listu cijelih brojeva počevši od 0 i *ne uključujući* argument
  - s dva argumenta – prvi argument određuje prvi broj liste
  - ako se navede i treći argument, on određuje korak

- raspon može uključivati i negativne brojeve, a može biti i silazan (negativan korak!)

```
>>> range(-5, 5)
[-5, -4, -3, -2, -1, 0, 1, 2, 3, 4]

>>> range(5, -5, -1)
[5, 4, 3, 2, 1, 0, -1, -2, -3, -4]
```

Funkcija `range` (2)

- generirani raspon (lista) može se koristiti kao sekvenca kroz koju iteira petlja `for`

```
>>> for i in range(3):
...   print i, 'Pythons'
...
0 Pythons
1 Pythons
2 Pythons
```

- indeksiranje elemenata liste

```
>>> L = [1, 2, 3, 4, 5]
>>>
>>> for i in range(len(L)):
...   L[i] += 1
...
>>> L
[2, 3, 4, 5, 6]
```

Funkcija `zip`

- ugrađena funkcija `zip` omogućava paralelno iteriranje kroz više sekvenci
  - funkcija kao argumente prima jednu ili više sekvenci, a vraća listu n-torki koje uparuju/združuju elemente tih sekvenci

```
>>> L1 = [1,2,3]
>>> L2 = [5,6,7]

>>> zip(L1,L2)
[(1, 5), (2, 6), (3, 7)]
```

  - rezultat može poslužiti za istovemeni prolazak kroz obje sekvence

```
>>> for (x,y) in zip(L1, L2):
...   print x, y, '--', x+y
...
1 5 -- 6
2 6 -- 8
3 7 -- 10
```

Funkcija `zip` (2)

- funkcija `zip` može se iskoristiti i za inicijalizaciju rječnika
  - recimo da imamo izgrađene liste ključeva i vrijednosti koje želimo upariti u rječniku

```
>>> keys = ['spam', 'eggs', 'toast']
>>> vals = [1, 3, 5]

>>> D2 = { }
>>> for (k, v) in zip(keys, vals): D2[k] = v
...
>>> D2
{'toast': 5, 'eggs': 3, 'spam': 1}
```

  - može i bolje – konstruktoru rječnika može se predati lista kreirana funkcijom `zip`

```
>>> D3 = dict(zip(keys, vals))
>>> D3
{'toast': 5, 'eggs': 3, 'spam': 1}
```

Funkcije

- funkcije u Pythonu ponašaju se drugačije nego funkcije u prevođenim jezicima
- funkcija se definira *naredbom* **`def`**
  - `def` je naredba koja se *izvršava*
  - funkcija *ne postoji* dok se ne izvrši `def`
  - moguće je gnijezditi naredbu `def` unutar petlji, `if` konstrukcija, pa i unutar drugih naredbi `def`
  - tipično se naredba `def` koristi u *modulima*, gdje generiraju funkcije prilikom prvog učitavanja modula
  - `def` stvara *objekt* funkciju i pridružuje ga imenu – ime je *referenca* na funkciju (objekt)

Funkcije (2)

- oblik naredbe `def`

```
def <name>(arg1, arg2,... argN):
    <statements>
    ...
    return <value> #nije obavezno
```

  - tipična složena naredba s retkom zaglavlja
  - blok naredbi postaje tijelo funkcije – kôd koji se izvršava svaki put kada se funkcija pozove
  - imena argumenata navedena u zaglavlju definicije funkcije pridružuju se objektima koji se pri pozivu prosljeđuju funkciji
  - naredba `return` može se pojaviti bilo gdje u tijelu funkcije
    - završava se izvršavanje funkcije i vraća rezultat pozivateljuž
    - ako je nema, funkcija vraća objekt `None`

Funkcija je objekt

- `def` je naredba koja se *izvršava* – objekt-funkcija nastaje tijekom izvođenja programa

```
if test:
   def func( ): # jedna definicija
       ...
else:
   def func( ): # alternativna definicija
       ...
...
func( ) # poziv odabrane verzije
```

- funkcija je objekt, a njeno ime je referenca

```
othername = func # objekt se pridruzuje drugom imenu
othername( ) # poziv iste funkcije drugim imenom
```

Definicija i poziv funkcije

- primjer funkcije

```
>>> def times(x, y):
...   return x * y # tijelo se izvodi pri pozivu
...
```

- poziv funkcije

```
>>> times(2, 4) # argumenti u zagradama
8
```

- rezultat se može pohraniti

```
>>> x = times(3.14, 4)
>>> x
12.56
```

- tip argumenata nije zadan

```
>>> times('Ni', 4)
'NiNiNiNi'
```

  - inherentan *polimorfizam*

Primjer

- funkcija koja određuje presjek dviju sekvenci

```
def intersect(seq1, seq2):
    res = [  ]    # lokalna varijabla, prazna lista
    for x in seq1:          # scan seq1
        if x in seq2:       # common item?
            res.append(x)   # add to end
    return res
```

- poziv

```
>>> s1 = "SPAM"
>>> s2 = "SCAM"

>>> intersect(s1, s2) # strings
['S', 'A', 'M']
```

- polimorfizam – proslijeđeni objekti moraju podržavati operacije u funkciji (ovdje: prvi – iteriranje s `for`, drugi – operator `in`)

```
>>> intersect([1, 2, 3], (1, 4)) # mixed types
[1]
```

Doseg varijabli

- imena nastaju kad im se prvi put dodijeli vrijednost
- na temelju mjesta u programu gdje se dodjeljivanje vrijednosti obavlja, Python povezuje ime s odgovarajućim *prostorom imena*, odnosno određuje *doseg* (*scope*) u kojem je ime vidljivo
- imena definirana unutar funkcije su *lokalna* – vidljiva samo unutar funkcije
  - ne može doći do sukoba imena s imenima van funkcije
  - svaki poziv funkcije stvara *novi* lokalni doseg
  - ime u funkciji moguće je deklarirati *globalnim*
- svaki modul predstavlja *globalni* doseg
  - globalne varijable su atributi modula
  - globalni doseg se proteže najviše kroz jednu datoteku (modul)

Razrješavanje imena

- razrješavanje imena može se sažeti u tri jednostavna pravila:
  - referenca imena traži se u najviše četiri dosega (LEGB), i to sljedećim redom:
    - lokalni – L
    - doseg obuhvaćajuće (*enclosing*) funkcije – E
    - globalni – G
    - ugrađeni (*built-in*) – B
  - dodjela vrijednosti stvara ili mijenja *lokalno* ime *by default*
  - globalne deklaracije mapiraju imena u doseg obuhvaćajućeg modula
- funkcije mogu *koristiti* imena iz obuhvaćajućeg(E) ili globalnog (G) dosega, ali ih *ne mogu mijenjati* ako ih ne deklariraju globalnima
- ovaj način razrješavanja primjenjuje se za *jednostavna* imena varijabli, za kvalificirana imena (`objekt.atribut`) primjenjuju se drugačija pravila

Razrješavanje imena (2)

- primjer

```
# Global scope
X = 99 # global

def func(Y):
    # local scope
    Z = X + Y # X is a global
    return Z

func(1) # func in module: result=100
```

  - globalna imena: `X` i `func`, `X` se može koristiti unutar funkcije bez posebnog deklariranja
  - lokalna imena funkcije `func`: `Y` i `Z`
    - postoje samo tijekom izvršavanja funkcije, vrijednost im se dodjeljuje u definiciji funkcije
    - argumenti (`Y`) se uvijek prosljeđuju *pridruživanjem*

Razrješavanje imena (3)

- budući da se imena traže zadanim redosljedom dosega (LEGB), uvođenje istog imena u lokalni doseg *zakriva* globalno ime

```
X = 88          # Global X

def func( ):
    X = 99      # Local X: hides global

func( )
print X         # Prints 88: unchanged
```

  - dodjela vrijednosti varijabli `X` unutar funkcije stvara *lokalnu* varijablu `X`
  - to je varijabla koja nema nikakve veze s globalnom varijablom `X` u modulu izvan funkcije
  - da bi funkcija mogla mijenjati globalnu varijablu, mora je proglasiti globalnom

Naredba `global`

- naredba `global` je jedina “stvar” u Pythonu koja *podsjeća* na deklaraciju :-)
  - iza ključne riječi `global` navode se imena varijabli odvojena zarezima
  - navedena imena se mapiraju u doseg obuhvaćajućeg modula

```
X = 88          # Global X

def func( ):
    global X
    X = 99 # mijenja globalnu varijablu

func( )
print X         # Prints 99
```

Prenošenje argumenata u funkcije

- argumenti se prenose *dodjeljivanjem*
  - automatsko dodjeljivanje objekata lokalnim imenima $\rightarrow$ argumenti funkcije su reference na potencijalno dijeljene objekte koje referencira pozivatelj
  - dodjela *imenu* argumenta unutar funkcije *ne utječe* na pozivatelja – *doseg* imena je unutar funkcije
  - ako je argument izmjenljivi objekt, njegova izmjena u funkciji može utjecati na pozivatelja
- iako se zapravo prosljeđuju reference, ponašanje argumenata ovisi o njihovoj vrsti (izmjenljivosti)
  - nepromjenljivi argumenti se ponašaju *kao da su* proslijeđeni kao vrijednosti (iako se ne stvara kopija)
  - izmjenljivi argumenti ponašaju se kao da su proslijeđeni kao reference

Argumenti i dijeljene reference

- primjer

```
>>> def changer(x, y):
...   x = 2       # mijenja samo lokalnu vrijednost
...   y[0] = 'spam' # mijenja dijeljeni objekt
...
>>> X = 1
>>> L = [1, 2] # pozivatelj
>>> changer(X, L) # immutable and mutable
>>> X, L       # X nepromijenjen, L razlicit
(1, ['spam', 2])
```

- `x` je lokalno ime, dodjeljuje mu se novi objekt, veza globalne varijable `X` i objekta `1` nije narušena
- dodjela `y[0] = 'spam'` mijenja element liste `L`

Argumenti i dijeljene reference (2)

- radi se naprosto o *dijeljenim referencama*

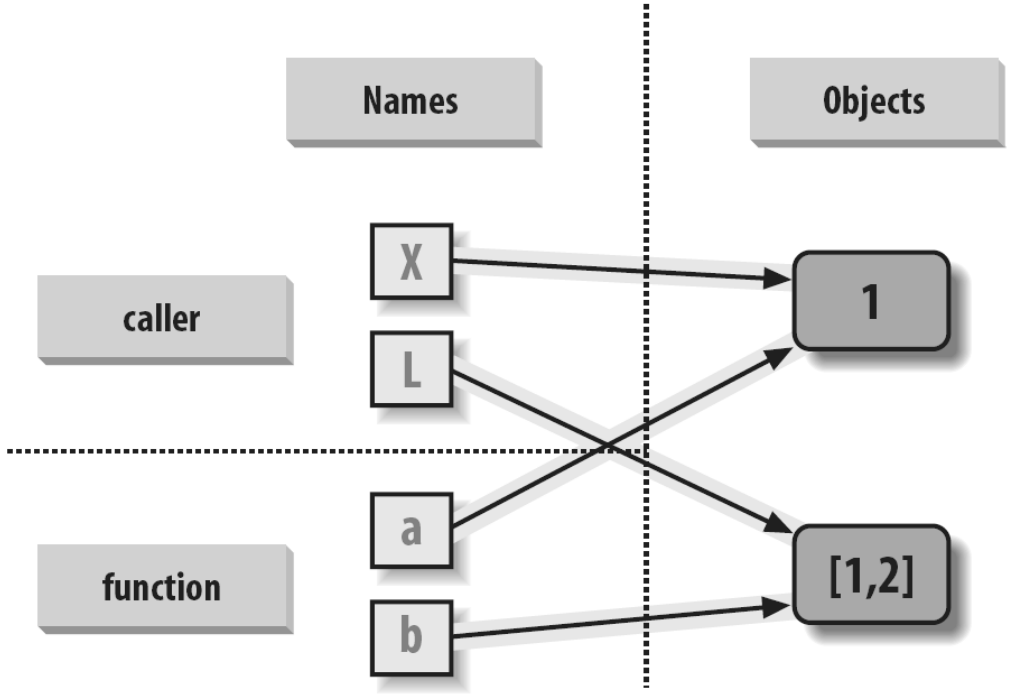

Izbjegavanje izmjene argumenata

- ako želimo spriječiti izmjenu izmjenljivih objekata proslijeđenih u funkciju, možemo proslijediti eksplicitnu *kopiju*

```
L = [1, 2]
changer(X, L[:]) # prosljedjuje se kopija
```

- kopiju može napraviti i sama funkcija

```
def changer(x, y):
   y = y[:]     # kopija !
   x = 2
   y[0] = 'spam' # izmjena na kopiji
```

- možemo i objekt pretvoriti u nepromjenljivi

```
L = [1, 2]
changer(X, tuple(L)) # nepromjenljiv objekt
```

  - *upozorenje*: izvorna lista može sadržavati i promjenljive objekte – niti kopija niti pretvorba u n-torku ne može spriječiti mijenjanje tih ugniježdenih objekata !

Oponašanje izlaznih argumenata

- Python nema mehanizam poziva s referencom (*call-by-reference*)
- možemo ga oponašati tako da se izlazni parametri vrate kao n-torka, koja se dodjeljuje izvornim argumentima u pozivatelju

```
>>> def multiple(x, y):
...     x = 2 # mijenjaju se lokalna imena
...     y = [3, 4]
...     return x, y # povratna n-torka
...
>>> X = 1
>>> L = [1, 2]
>>> X, L = multiple(X, L) # povratna dodjela rezultat
>>> X, L
(2, [3, 4])
```

  - konačan rezultat je izmjena izvornih argumenata

Posebni načini imenovanja argumenata

- uobičajeni način dodjele imena argumentima funkcije je *pozicijski* – pri pozivu se argumenti navode istim redoslijedom kao u definiciji funkcije, mora ih biti jednak broj
- Python nudi i druge mogućnosti, koje omogućuju dodatnu fleksibilnost
  - podudaranje argumenata imenom (*keywords*) pri pozivu funkcije – argumenti se mogu navesti proizvoljnim redosljedom
  - pretpostavljene vrijednosti za argumenate koji se na proslijede (*default*) – omogućava pozivanje funkcije s “manjkom” argumenata
  - preuzimanje promjenjivog broja argumenata (*varargs*) – omogućava pozivanje funkcije s “viškom” argumenata

Dodjela imena argumentima

- pozicijsko i imenovano povezivanje argumenata

```
>>> def f(a, b, c): print a, b, c
...
>>> f(1, 2, 3) # pozicijsko povezivanje
1 2 3

>>> f(c=1, b=3, a=2) # povezivanje imenom
2 3 1

>>> f(3, c=2, b=1) # mijesano
3 1 2
```

  - broj argumenata u pozivu mora odgovarati broju argumenata u definiciji funkcije
  - u slučaju miješanog povezivanja imena, najprije se dodjeljuju pozicijski argumenti, s lijeva udesno

    ```
    >>> f(3, c=2, a=1) # ne valja!
    ```

Pretpostavljene vrijednosti argumenata

- pretpostavljene vrijednosti argumenata omogućavaju da neki argumenti pri pozivu budu opcionalni – ako se argument ne proslijedi, dodjeljuje mu se pretpostavljena vrijednost

```
>>> def f(a, b=2, c=3): print a, b, c
...
>>> f(1) # moramo proslijediti vrijednost za a
1 2 3

>>> f(a=1) # moze i po imenu
1 2 3

>>> f(1, 4)
1 4 3

>>> f(1, 4, 5)
1 4 5

>>> f(1, c=6) # imenovanje pomaze
1 2 6
```

Proizvoljna lista argumenata

- Pyton nudi mogućnost prosljeđivanja proizvoljnog broja argumenata
- prvi oblik primjene prikuplja prekobrojne argumente u n-torku

```
>>> def f(*args): print args
...
>>> f( )
( )

>>> f(1)
(1,)

>>> f(1,2,3,4)
(1, 2, 3, 4)
```

Proizvoljna lista argumenata (2)

- drugi oblik radi samo za pridruživanje argumenata imenom, a argumenti se prikupljaju u rječnik

```
>>> def f(**args): print args
...
>>> f( )
{ }

>>> f(a=1, b=2)
{'a': 1, 'b': 2}
```

- moguće je i kombiniranje

```
>>> def f(a, *pargs, **kargs): print a, pargs, kargs
...
>>> f(1, 2, 3, x=1, y=2)
1 (2, 3) {'y': 2, 'x': 1}

>>> f(1, 2, 3, x=1, y=2, 4, 5) # ovo ipak ne ide
SyntaxError: non-keyword arg after keyword arg
```

Bezimene funkcije (lambda izrazi)

- *lambda izrazi* omogućavaju generiranje funkcijskih objekata izrazom – bez definicije i bez imena (anonimna funkcija)
  - *izraz* a ne naredba – može se pojaviti na mjestima gdje sintaksa ne dozvoljava `def`, npr. unutar liste ili u pozivu funkcije
  - kao izraz, lambda vraća vrijednost (novu funkciju), kojoj se može dodijeliti ime (ali i ne mora)
- opći oblik:

  `lambda` `argument1, argument2,... argumentN : izraz`
  - nakon ključne riječi `lambda` navode se argumenti, koji se koriste u izrazu
  - generirana funkcija radi jednako kao i funkcija stvorena naredbom `def`
  - tijelo lambda funkcije je *jedan izraz*
    $\rightarrow$ ograničena funkcionalnost

Bezimene funkcije (2)

- primjer

```
>>> f = lambda x, y, z: x + y + z
>>> f(2, 3, 4) # normalan poziv
9
```

- pretpostavljene vrijednosti argumenata rade i za lambda funkcije

```
>>> x = (lambda a="fee", b="fie", c="foe": a + b + c)
>>> x("wee")
'weefiefoe'
```

- pravila za razrješavanje imena (dosega) vrijede

```
>>> def knights( ):
...     title = 'Sir'
...     action = (lambda x: title + ' ' + x) # title
...     return action                        # vraca funkciju
...
>>> act = knights( )
>>> act('robin')
'Sir robin'
```

Bezimene funkcije (3)

- čemu uopće lambda izrazi ?
  - način da ugradimo definiciju funkcije unutar kôda koji ju koristi – npr. povratne funkcije (*callback handlers*) kodirane kao lambda izrazi u samom pozivu za registriranje
  - tablice grananja pohranjene u listi ili rječniku

```
L = [(lambda x: x**2), (lambda x: x**3),
                       (lambda x: x**4)]
for f in L:
   print f(2) # ispisuje 4, 8, 16
print L[0](3) # ispisuje 9
```

  - ostvarenje višestrukog grananja rječnikom:

```
>>> key = 'got'
>>> {'already': (lambda: 2 + 2),
... 'got':   (lambda: 2 * 4),
... 'one':   (lambda: 2 ** 6)
... }[key]( )
8
```

Još malo o modulima

- koncept modula smo upoznali (slajdovi 8–15)
  - datoteka s nastavkom imena `".py"` je modul
  - modul se može učitati naredbama `import` ili `from`
  - prilikom *prvog* učitavanja izvršavaju se naredbe modula i stvara objekt modul
  - globalna imena modula (atributi) postaju dostupna
    - ako je modul učitan s `import modul`, atributima se pristupa *kvalifikacijom*: `modul.atribut`
    - ako je modul učitan s `from modul import atribut`, imena atributa *kopiraju se* u prostor imena učitavatelja
    - naredbom `from modul import *`, kopiraju se imena svih atributa učitanog modula
  - ukoliko je potrebno ponovo učitati modul (npr. promijenli smo ga), koristi se ugrađena funkcija `reload`

Moduli i prostori imena

- kao i `def`, `import` i `from` su *naredbe* – modul i njegova imena nisu raspoloživi dok se naredba učitavanja ne izvrši
- kao i `def`, `import` i `from` su implicitna dodjeljivanja
  - `import` cijeli modul kao objekt dodjeljuje jednom imenu
  - `from` kopira jedno ili više imena – ta imena postaju reference na dijeljene objekte
  - dodjela novog objekta imenu ne utječe na objekte u modulu
  - izmjena (izmjenljivog) objekta preko imena u učitavatelju utječe na objekt u učitanom modulu
- primjer

```
# modul small.py
x = 1
y = [1, 2]
```

Moduli i prostori imena (2)

- primjer (nastavak)

```
$ python
>>> from small import x, y # kopiramo imena
>>> x = 42 # mijenja se lokalna kopija
>>> y[0] = 42 # mijenjamo izvorni objekt

>>> import small # nedostaje nam referenca objekta
>>> small.x # to je drugi x
1
>>> small.y # ali listu y dijelimo
[42, 2]

>>> reload(small) # nanovo stvaramo objekt modul
>>> small.y # obnovljen
[1, 2]
>>> y # ovaj pokazuje na stari objekt
[42, 2]
```

Moduli i prostori imena (3)

- za učitani modul globalni prostor imena je datoteka u kojoj je definiran – ne vidi prostor imena modula koji ga je učitao

```
# modul moda.py
X = 88 # globalna varijabla za ovaj modul

def f( ):
  global X # mijenja globalnu var OVOG MODULA
  X = 99  # ne vidi imena u drugim modulima
```

```
# modul modb.py
X = 11    # i on ima svoj globalni X
import moda
moda.f( ) # postavlja moda.X, a ne X iz ovog modula
print X, moda.X
```

```
$ python modb.py
11 99
```

Moduli i prostori imena (4)

- gniježdenje modula

```
# modul mod3.py
X = 3
```

```
# modul mod2.py
X = 2
import mod3
print X, mod3.X
```

```
# modul mod1.py
X = 1
import mod2
print X, mod2.X,
print mod2.mod3.X # nested mod3's X
```

```
$ python mod1.py
2 3
1 2 3
```

Skrivanje podataka u modulu

- modul u Pythonu eksportira sva imena dodjeljena u najvišj razini datoteke u kojoj se nalazi
  - nema načina za sprječavanje klijenta da promijeni ime u modulu ako to baš želi
  - u Pythonu je skrivanje podataka u modulu *konvencija* a ne sintaktičko ograničenje
- naredba `from *` zapravo *ne kopira sva* imena učitanog modula
  - imena koja započinju znakom `"_"` (podvlaka) ne kopiraju se naredbom `from *`
  - namjera je smanjivanje “onečišćenja” prostora imena (ne kopiraju se imena koja nisu predviđena za korištenje od strane klijenta), a ne *zabrana* izmjene
  - ako to želimo, izmjena je i za takva imena moguća nakon učitavanja modula naredbom `import`

Skrivanje podataka u modulu (2)

- sličan efekt može se postići dodjelom liste stringova s imenima varijabli koje želimo eksportirati varijabli `__all__` u najvišoj razini modula

```
__all__ = ["Error", "encode", "decode"]
                          # Export these only
```

  - i ovaj oblik skrivanja odnosi se *samo* na `from *` oblik učitavanja modula
  - Python najprije traži `__all__` listu unutar modula
  - ako takva lista nije definirana, kopiraju se sva imena bez vodeće podvlake

Klase i OOP

- i do sada smo koristili pojam *objekt*, a vidjeli smo i objekte koji imaju *metode*
- Python podržava i oblikovanje novih tipova objekata – *klasa*, te *nasljeđivanje*
- stvaranje novog tipa objekta ostvaruje se naredbom **`class`**
- novi tipovi objekata mogu se oblikovati tako da se ponašaju slično ugrađenim tipovim objektima
- nasljeđivanje je mehanizam koji podupire prilagođavanje i višestruko korištenje koda
- korištenje OOP u Pythonu je neobavezno, ali kako ga koriste mnogi alati, dobro je steći barem grubu sliku o ovim konceptima

Nasljeđivanje kao pretraživanje

- objekt ima *atribute*, a pristup atributu započinje izrazom poput `objekt.atribut`
  - kad se ovakav izraz primijeni na objekt izveden na temelju naredbe `class`, pokreće se operacija *pretraživanja* stabla povezanih objekata – traži se *prvo pojavljivanje* atributa
  - stablo se pretražuje od dna prema vrhu, krenuvši od samog objekta, pa zatim kroz klase iz kojih je izveden → *nasljeđivanje*
  - objekti niže u stablu *nasljeđuju* atribute objekata smještenih više u stablu
- u Pythonu je ovaj koncept doista i izveden kao pretraživanje – u kôdu gradimo stablastu strukturu povezanih objekata, a Python tijekom izvođenja programa pokreće pretraživanje svaki put kada naiđe na izraz tipa `objekt.atribut`

Nasljeđivanje kao pretraživanje (2)

- primjer – stablo pretraživanja

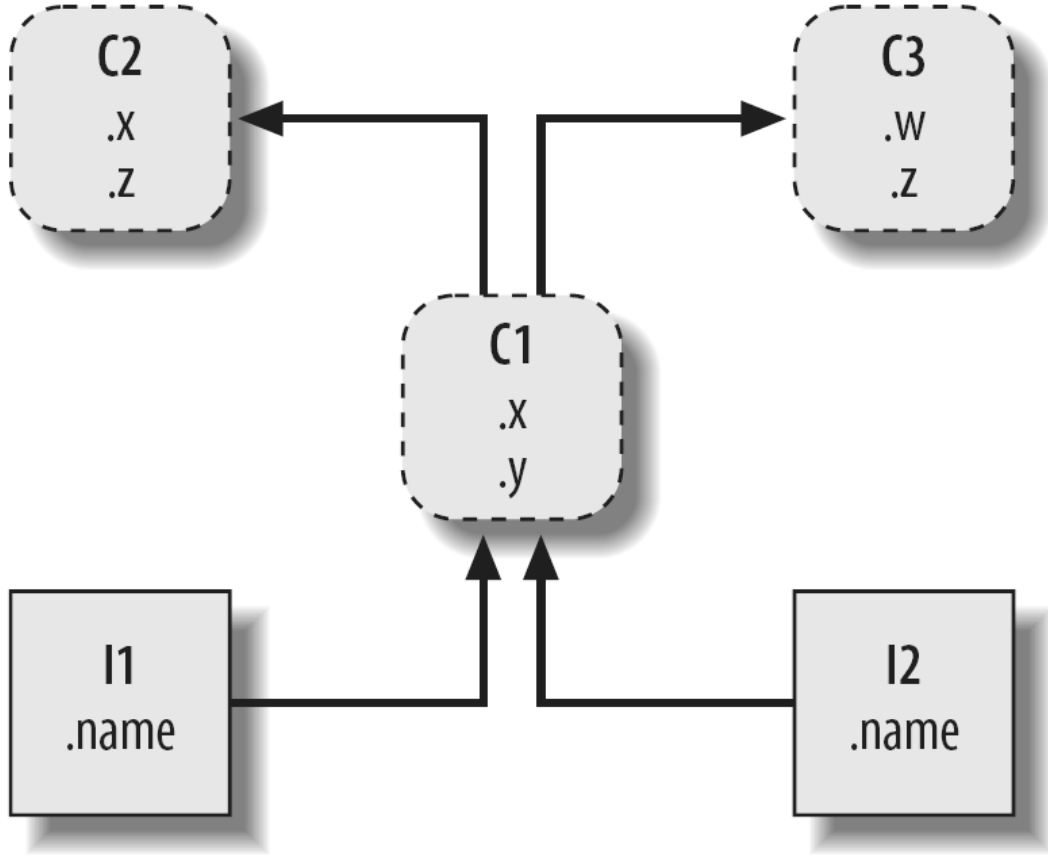

Nasljeđivanje kao pretraživanje (3)

- *razred* (*klasa*) – objekt koji svojim atributima (podaci i funkcije) definira ponašanje koje nasljeđuju svi *primjerci* (*instance*) koji se iz te klase generiraju
- *primjerak* predstavlja konkretni objekt u domeni programa, njegovi atributi sadrže podatke koji variraju od primjerka do primjerka
- primjerak nasljeđuje atribute svojeg razreda, a razred atribute svojih *nad-razreda*
  - odgovara stablu pretraživanja
  - kako pretraživanje napreduje od dna prema vrhu, podklasa može izmijeniti (*override*) ponašanje definirano u nadklasi

Nasljeđivanje kao pretraživanje (4)

- primjer sa slike, izraz `I2.w`
  - primjer nasljeđivanja
  - započinje pretraživanje stabla prikazanog na slici (str. 163)
  - Python traži atribut `w` počevši od `I2`, prema vrhu stabla, pretraživanjem povezanih objekata `I2, C1, C2, C3`
  - staje prvim nailaskom na atribut odgovarajućeg imena – u ovom slučaju `C3.w` item drugim riječima, `I2` nasljeđuje atribut `w` od `C3`
- referenciranje drugih atributa završava pretraživanjem drugih grana stabla
  - `I1.x` i `I2.x` pronalaze `x` u `C1` jer je niže u stablu od `C2` – *overriding*
  - `I1.y` i `I2.y` pronalaze `C1.y`
  - `I1.z` i `I2.z` pronalaze `C2.y` – pretraživanje je *s lijeva u desno*
  - `I2.name` pronalazi `name` u `I2` bez penjanja uz stablo

Razredi

- naredba **`class`** generira novi *objekt razred*

```
class C2: ... # novi razred
class C3: ...
class C1(C2, C3): ... # nasljedjuje C2 i C3
```

  - razredi se povezuju sa svojim nad-razredima njihovim navođenjem u zagradama; redoslijed navođenja određuje redoslijed pretraživanja u stablu
  - primjer višestrukog nasljeđivanja
- *poziv razreda* generira novi *primjerak* razreda

```
I1 = C1( ) # novi primjerci razreda C1
I2 = C1( )
```

  - primjerci se automatski povezuju s razredima iz kojih su generirani

Razredi (2)

- zbog načina na koji se izvodi pretraživanje/nasljeđivanje, izbor objekta za koji se veže atribut je ključan – on određuje doseg imena
  - atributi vezani za primjerke, odnose se samo na konkretan primjerak
  - atribute vezane za razred *dijele* svi pod-razredi i svi primjerci izvedeni iz tog razreda
  - atributi koji su vezani uz razred obično se stvaraju dodjelom u naredbama unutar definicije razreda
  - atributi vezani za primjerke obično se stvaraju dodjelama posebnom argumentu `self` koji se prosljeđuje funkcijama unutar razreda

```
class C1(C2, C3):
   def setname(self, who): # C1.setname
      self.name = who # self je I1 ili I2
```

Razredi (3)

- stvaranje primjerka i dodjela vrijednosti atributu

```
I1 = C1( ) # stvaranje primjeraka
I2 = C1( )
I1.setname('bob') # postavlja I1.name u 'bob'
I2.setname('mel')
print I1.name # ispisuje 'bob'
```

  - kada se `def` nađe unutar definicije razreda, smatra se *metodom* i automatski dobiva poseban prvi argument
    - po *konvenciji* se naziva `self`
    - osigurava referencu na primjerak iz kojeg se metoda poziva
    - kao `this` u C++ ili Java, ali u Pythonu je `self` uvijek eksplicitan

Konstruktor

- prilikom stvaranja primjerka (instanciranja) ponekad želimo inicijalizirati neke njegove elemente

```
class C1(C2, C3):
    def __init__(self, who):
                # postavi name pri konstrukciji
        self.name = who # self je I1 ili I2

I1 = C1('bob') # postavlja I1.name u 'bob'
I2 = C1('mel')
```

  - metoda imena `__init__` poziva se automatski kad god se generira novi primjerak razreda – *konstruktor*
  - prvi argument `self` automatski se prosljeđuje zajedno s listom ostalih, navedenih argumenata
  - šira skupina metoda – za preopterećivanje (*overloading*) operatora: npr. metoda `__and__` preopterećuje operator `&`, a `__sub__` operator `-`

Primjer

- primjer: baza podataka o zaposlenicima
  - bazni razred definira pretpostavljeno ponašanje zajedničko svim vrstama zaposlenika u poduzeću:

```
class Employee: # temeljna nadklasa
   def computeSalary(self): ... # zajednicko
   def giveRaise(self): ...
   def promote(self): ...
   def retire(self): ...
```

  - specijalizacija – prilagodba ponašanja za neku vrstu zaposlenika → izvedeni podrazred koji zamjenjuje (*override*) metodu za izračun plaće

```
class Engineer(Employee): # podklasa
   def computeSalary(self): ... # prilagodba
```

  - primjerci mogu biti generirani iz osnovnog ili iz izvedenog razreda

```
bob = Employee( ) # osnovno ponasanje
mel = Engineer( ) # izmijenjeno ponasanje
```